

**SEGMENTASI NODUL KANKER PARU-PARU
BERDASARKAN CITRA CT SCAN PARU
MANUSIA MENGGUNAKAN
*ATTENTION U-NET***

SKRIPSI



Arzalia Ardheasari

11170940000051

Universitas Islam Negeri
SYARIF HIDAYATULLAH JAKARTA

**PROGRAM STUDI MATEMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA
2023 M/1444 H**

**SEGMENTASI NODUL KANKER PARU-PARU
BERDASARKAN CITRA CT SCAN PARU
MANUSIA MENGGUNAKAN
*ATTENTION U-NET***

Skripsi

Diajukan kepada
Universitas Islam Negeri Syarif Hidayatullah Jakarta
Fakultas Sains dan Teknologi
Untuk Memenuhi Salah Satu Persyaratan dalam
Memperoleh Gelar Sarjana Matematika (S.Mat)

Oleh:

Arzalia Ardheasari

11170940000051

Universitas Islam Negeri
SYARIF HIDAYATULLAH JAKARTA

**PROGRAM STUDI MATEMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UIN SYARIF HIDAYATULLAH JAKARTA
2023 M/1444 H**

PERNYATAAN KEASLIAN

DENGAN INI SAYA MENYATAKAN BAHWA SKRIPSI INI BENAR-BENAR HASIL KARYA SENDIRI YANG BELUM PERNAH DIAJUKAN SEBAGAI SKRIPSI ATAU KARYA ILMIAH PADA PERGURUAN TINGGI ATAU LEMBAGA MANAPUN.

Tangerang Selatan, 13 Oktober 2023



Arzalia Ardheasari
11170940000051



Universitas Islam Negeri
AR-RANIRY
YARIF HIDAYATULLAH JAKARTA

PERSEMBAHAN DAN MOTTO

Segala puji syukur penulis panjatkan kepada Allah SWT serta shalawat dan salam kepada Nabi Muhammad SAW, karena atas rahmat dan hidayah-Nya penulis mampu menyelesaikan skripsi ini.

Skripsi ini penulis persembahkan untuk kedua orang tua, kedua adik, dan teman-teman yang selalu memberikan semangat dan doa yang tulus.

MOTTO

“Pada akhirnya takdir Allah selalu baik walaupun terkadang perlu air mata untuk menerimanya”

-Umar Bin Khattab-

Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA

ABSTRAK

Arzalia Ardheasari, Segmentasi Nodul Kanker Paru-Paru Berdasarkan Citra CT Scan Paru Manusia Menggunakan *Attention U-Net*, di bawah bimbingan **Muhaza Liebenlito, M.Si** dan **Prof. Dr. Nur Inayah, M.Si**.

Pada tahun 2020, angka kematian kanker tertinggi dimiliki oleh kanker paru-paru dengan 1,80 juta kematian [1]. WHO menyatakan bahwa angka kematian dapat dikurangi dengan melakukan deteksi dini. Penelitian ini memanfaatkan metode *deep learning* berupa *Attention U-Net* yang memanfaatkan *attention gate* pada skip koneksi *U-Net* dasar untuk mensegmentasi area nodul kanker paru-paru. Proses segmentasi ini sebagai tahapan awal dalam mendiagnosis suatu penyakit. Data yang digunakan berupa CT scan LIDC-IDRI pasien kanker paru-paru yang terdiri dari 1000 irisan CT scan kanker paru dan 1000 irisan masks kanker paru. Data tersebut dilatih dengan melakukan *hyperparameter tuning* terlebih dahulu pada *learning rate* dan *batch size* agar meningkatkan kinerja segmentasi. Hasil penelitian didapatkan kombinasi nilai *hyperparameter learning rate* sebesar 0.01 dan *batch size* sebesar 16 menjadi nilai *hyperparameter* yang paling optimal untuk model *Attention U-Net* dengan memperoleh nilai *dice coefficient*, *recall*, dan *precision* masing-masing sebesar 0.9415 ; 0.9821 ; 0.9771. Hasil tersebut berhasil menggungguli model *U-Net* dasar.

Kata Kunci: Kanker Paru-Paru, *Attention U-Net*, Segmentasi, *Hyperparameter Tuning*

Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA

ABSTRACT

Arzalia Ardheasari, Lung Cancer Nodule Segmentation Based on Human CT Scan Image Using Attention U-Net, under the guidance of **Muhaza Liebenlito, M.Si** dan **Prof. Dr. Nur Inayah, M.Si**.

In 2020, the highest cancer mortality rate belongs to lung cancer with 1.80 million deaths [1]. WHO states that the mortality rate can be reduced by doing early detection. This research use deep learning method in the form of Attention U-Net which utilizes the attention gate on the basic U-Net skip connection to segment the lung cancer nodule area. This segmentation process is the initial stage in diagnosing a disease. The data used are CT scans of LIDC-IDRI lung cancer patients consisting of 1000 slices of CT scans of lung cancer and 1000 slices of lung cancer masks. The data is trained by performing hyperparameter tuning first on the learning rate and batch size in order to improve segmentation performance. The results showed that the combination of learning rate hyperparameter value of 0.01 and batch size of 16 became the most optimal hyperparameter value for the Attention U-Net model by obtaining dice coefficient, recall, and precision values of 0.9415 ; 0.9821 ; 0.9771, respectively. These results successfully outperformed the basic U-Net model.

Keywords: Lung Cancer, Attention U-Net, Segmentation, Hyperparameter Tuning

Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA

KATA PENGANTAR

Assalamualaikum Wr. Wb.

Puji syukur kehadiran Allah SWT atas segala rahmat yang telah melimpahkan rahmat dan hidayat-Nya. Shalawat serta salam penulis panjatkan kepada Nabi Muhammad SAW sehingga penulis bisa menyelesaikan skripsi ini yang berjudul **“Segmentasi Nodul Kanker Paru-Paru Berdasarkan Citra CT Scan Paru Manusia Menggunakan *Attention U-Net*”** sebagai syarat untuk memperoleh gelar sarjana Matematika pada program studi Matematika, Fakultas Sains dan Teknologi, Universitas Islam Negeri Syarif Hidayatullah Jakarta. Penulis menghaturkan terima kasih kepada semua pihak yang telah memberikan bimbingan, pengarahan, nasihat dan semangat selama pembuatan skripsi ini hingga diselesaikan dengan baik. Maka dari itu, penulis menyampaikan terima kasih kepada:

1. Bapak Husni Teja Sukmana, S.T., M.Sc, Ph.D selaku Dekan Fakultas Sains dan Teknologi Universitas Islam Negeri Syarif Hidayatullah Jakarta.
2. Bapak Taufik Edy Sutanto, M.Sc.Tech.,Ph.D selaku Ketua Program Studi Matematika Fakultas Sains dan Teknologi UIN Syarif Hidayatullah Jakarta.
3. Bapak Muhaza Liebenlito, M.Si selaku pembimbing I dan Ibu Prof. Dr. Nur Inayah, M.Si selaku pembimbing II, terima kasih atas pengarahannya dan sarannya selama pembuatan skripsi ini.
4. Bapak Taufik Edy Sutanto, M.Sc.Tech.,Ph.D selaku penguji I dan Ibu Dr. Suma'inna, M.Si selaku penguji II atas segala saran dan kritiknya serta bersedia menghadiri seminar hasil dan sidang skripsi.
5. Seluruh Dosen Program Studi Matematika yang telah memberikan ilmu-ilmunya dan pengalaman yang bermanfaat.
6. Kedua orang tua dan kedua adik penulis yang tidak pernah bosan memberikan doa, kasih sayang, semangat, dan dukungan moril maupun materil sehingga skripsi ini dapat terselesaikan.

7. Teman-teman diskusi penulis yaitu Mufi, Hana, Soraya, Fita, Adel, dan Nabilah yang selalu memberikan semangat dan saran kepada penulis.
8. Seluruh teman-teman Matematika angkatan 2017 yang tidak bisa disebutkan satu persatu.
9. Seluruh pihak yang sudah membantu penulis dalam mengerjakan skripsi ini tanpa mengurangi rasa hormat penulis tidak dapat sebutkan satu persatu.

Dalam pembuatan skripsi ini, penulis menyadari bahwa masih jauh dari kesempurnaan dan ada banyak kekurangan yang masih harus diperbaiki. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun untuk penyempurnaan skripsi ini. Semoga skripsi ini dapat bermanfaat dan berguna bagi semua pihak.

Wassalamualaikum Wr. Wb.



DAFTAR ISI

PERNYATAAN KEASLIAN	ii
LEMBAR PENGESAHAN	iii
PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH UNTUK KEPENTINGAN AKADEMIS	iv
PERSEMBAHAN DAN MOTTO	v
ABSTRAK	vi
ABSTRACT	vii
KATA PENGANTAR	viii
DAFTAR ISI	x
DAFTAR GAMBAR	xii
BAB I PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	3
1.3 Tujuan Penelitian	3
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	4
BAB II LANDASAN TEORI	5
2.1 Penyakit Kanker Paru.....	5
2.2 Segmentasi Citra	5
2.3 Fungsi Aktivasi	6
2.4 <i>Loss Function</i>	7
2.5 <i>Adam optimizer</i>	7
2.6 <i>U-Net</i>	8

2.7	Metrik Evaluasi.....	10
BAB III METODOLOGI PENELITIAN		13
3.1	Sumber Data.....	13
3.2	Tahapan Penelitian.....	13
BAB IV HASIL DAN PEMBAHASAN		20
4.1	Hasil <i>Preprocessing</i> Data.....	20
4.2	Hasil <i>Hyperparameter Tuning</i>	20
4.3	Hasil Melatih Model	22
4.4	Hasil Evaluasi Setiap Model	24
4.5	Hasil Segmentasi Gambar Setiap Model.....	25
BAB V PENUTUP.....		27
5.1	Kesimpulan	27
5.2	Saran	27
REFERENSI.....		28

DAFTAR GAMBAR

Gambar 2.1 Contoh (a) sampel gambar, (b) segmentasi semantik, dan (c) segmentasi instance [15]	6
Gambar 2.2 Arsitektur <i>U-Net</i> [22].	8
Gambar 2.3 Contoh ilustrasi operasi konvolusi [24].	9
Gambar 2.4 Contoh ilustrasi operasi <i>max pooling</i> [25].	10
Gambar 2.5 Contoh ilustrasi operasi <i>upsampling</i> [25].....	10
Gambar 3.1 Contoh Data.....	13
Gambar 3.2 Alur Penelitian.....	14
Gambar 3.3 Arsitektur <i>Attention U-Net</i> [10].....	17
Gambar 3.4 Skema Alur Kerja <i>Attention Gate</i> [10].....	18
Gambar 4.1 Proses <i>Preprocessing Data</i>	20
Gambar 4.2 Plot Hasil <i>Hyperparameter Tuning Model Attention U-Net</i>	21
Gambar 4.3 Plot Hasil <i>Hyperparameter Tuning Model U-Net</i>	22
Gambar 4.4 Plot Nilai <i>Loss Model Attention U-Net</i> pada (a) data train dan (b) data val.....	23
Gambar 4.5 Plot Nilai <i>Loss Model U-Net</i> pada (a) data train dan (b) data val.....	24
Gambar 4.6 Perbandingan Hasil Segmentasi Gambar Nodul Kanker Paru-Paru Setiap Model dengan Image CT Scan Nodul Kanker Paru-Paru dan Ground Truth	25

Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pada ayat Al-Qur'an surah Asy-Syuraa ayat 80 yang berbunyi:

وَإِذَا مَرَضْتُ فَهُوَ يَشْفِينِي ۝

“Dan apabila aku sakit, Dialah (Allah) yang menyembuhkan aku.”

Ayat diatas menjelaskan bahwa setiap orang yang punya penyakit maka dengan izin Allah SWT penyakit tersebut akan hilang dan akan mendapatkan kesembuhan. Untuk itu kita sebagai manusia harus senantiasa berdoa dan bertawakal kepada Allah SWT, sebab setiap penyakit pasti ada obatnya. Selain berdoa dan bertawakal, manusia juga harus berusaha mencari tahu cara untuk menyembuhkan penyakit tersebut melalui dokter. Penanganan yang cepat dan pengobatan yang tepat maka dengan izin Allah SWT penyakit apa saja yang diderita akan memperoleh kesembuhan.

Kanker paru-paru adalah tumor paru-paru ganas yang ditandai dengan pertumbuhan sel-sel tidak terkendali di jaringan paru-paru. Gejala yang timbul diantaranya sesak napas, batuk, nyeri dada, perubahan suara, warna sputum berubah dan batuk darah [2]. Menurut WHO, kanker merupakan penyebab utama kematian di seluruh dunia, terhitung hampir 10 juta kematian akibat kanker. Kanker paru-paru memiliki angka kematian yang tinggi dibandingkan dengan kanker lainnya. Pada tahun 2020 angka kematian kanker tertinggi dimiliki oleh kanker paru-paru dengan 1,80 juta kematian [1]. WHO menyatakan bahwa angka kematian dapat dikurangi dengan melakukan deteksi dini dan pengobatan penyakit yang efektif.

Deteksi dini yang biasanya digunakan untuk diagnosis kanker paru-paru yaitu pencitraan CT scan pada pasien. Pencitraan CT scan memberikan gambaran organ dalam paru-paru sebagai pertimbangan ahli medis untuk mengetahui adanya sel kanker atau tidak pada paru-paru pasien. Hasil citra CT scan biasanya

menunjukkan bintik-bintik kecil putih pada bagian paru-paru yang disebut nodul paru. Nodul paru terbagi menjadi jinak dan ganas, pertumbuhan nodul paru ganas pada paru-paru manusia lama kelamaan akan menjadi kanker yang berbahaya [3].

Dalam dunia medis, tahapan awal mendiagnosis suatu penyakit dilakukan dengan segmentasi citra. Segmentasi citra merupakan proses membagi citra ke dalam beberapa objek berdasarkan kemiripan dari objek tersebut [4]. Segmentasi manual yang dilakukan ahli medis membutuhkan waktu yang lama dan hasil dari citra biasanya terdapat *noise* dan kontras rendah sehingga mengakibatkan turunnya kualitas gambar citra yang menyulitkan ahli medis membuat keputusan [2]. Untuk itu digunakan segmentasi citra menggunakan bantuan komputer.

Pada zaman kemajuan teknologi, peranan *deep learning* untuk tugas medical segmentasi mendapat minat yang besar karena kemampuannya yang cepat dan akurat. Model yang paling sering digunakan untuk tugas medical segmentasi yaitu *U-Net*. Beberapa peneliti yang menggunakan *U-Net* dalam tugas segmentasi diantaranya Yoo Seung-Jin dkk [5] mensegmentasi parenkim paru dengan kondisi patologis yang luas pada gambar CT scan dada non-kontras. Kemudian Yasuhisa Kurata dkk [6] melakukan segmentasi otomatis uterus pada dataset MRI, Hariyanti dkk [7] mensegmentasi kromosom untuk mengidentifikasi dan membedakan antara individu kromosom dan Pulung Hendro dkk [8] melakukan segmentasi citra fundus retina mata untuk mendiagnosis penyakit mata glaukoma.

Yingping Li dkk [9] melakukan segmentasi lesi otomatis menggunakan arsitektur *U-Net* dengan menyetel *hyperparameter* terlebih dahulu untuk meningkatkan kinerja segmentasi. Hasil penelitiannya menunjukkan nilai *Dice Coefficient* mengalami peningkatan dari 0.855 menjadi 0.929 dengan menyetel *hyperparameter* jaringan. Penyetelan *hyperparameter* yang dilakukan terdiri dari penyetelan data augmentasi, *learning rate*, *batch size*, dan *weight decay*.

Strategi efektif untuk mengurangi angka kematian penyakit yaitu mengembangkan metode yang akurat dan mempercepat identifikasinya. Ozan Oktay [10] mengusulkan model baru bernama *Attention-U-Net* yang berhasil mengungguli kinerja *U-Net* dalam tugas segmentasi pada dua CT Abdomen

pancreas. Model *Attention U-Net* memanfaatkan *attention gate* yang memangkas fitur yang tidak relevan dengan tugas yang sedang berlangsung. Penggunaan *attention gate* juga secara bertahap mampu meningkatkan kinerja segmentasi [10].

Berdasarkan pemaparan diatas, penulis tertarik mengatasi permasalahan segmentasi nodul kanker paru-paru pada citra CT scan menggunakan model *Attention U-Net* yang diperkenalkan oleh Ozan Oktay dkk [11]. Penulis akan melakukan penyetelan *hyperparameter* terlebih dahulu untuk meningkatkan kinerja segmentasi kemudian akan membandingkan hasilnya dengan model *U-Net* dasar. Penelitian ini diharapkan dapat membantu ahli medis dalam membaca hasil citra CT scan dengan cepat dan akurat sehingga dapat mengoptimalkan pengambilan keputusan ahli medis dalam mendiagnosis penyakit kanker paru-paru.

1.2 Rumusan Masalah

Permasalahan yang akan dibahas pada penelitian ini yaitu:

1. Berapa nilai *hyperparameter* yang paling optimal untuk segmentasi nodul kanker paru berdasarkan citra CT scan paru manusia?
2. Bagaimana performa model *Attention U-Net* dibandingkan dengan model *U-Net* berdasarkan nilai *dice coefficient*, *recall* dan *precision*?
3. Bagaimana hasil segmentasi gambar nodul kanker paru dengan model *Attention U-Net* dibandingkan dengan model *U-Net*?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini yaitu:

1. Mengetahui nilai *hyperparameter* yang paling optimal untuk segmentasi nodul kanker paru berdasarkan citra CT scan paru manusia.
2. Mengetahui performa model *Attention U-Net* dibandingkan dengan model *U-Net* berdasarkan nilai *dice coefficient*, *recall* dan *precision*.
3. Mengetahui hasil segmentasi gambar nodul kanker paru dengan model *Attention U-Net* dibandingkan dengan model *U-Net*.

1.4 Batasan Masalah

Beberapa batasan masalah penelitian ini yaitu:

1. Data yang digunakan didapat dari website *cancer imaging archive* berupa citra CT scan LIDC-IDRI pasien kanker paru-paru.
2. Data yang digunakan memakai irisan CT scan yang hanya terdapat nodul saja yaitu sebanyak 1000 Irisan citra CT scan kanker paru dan 1000 irisan mask citra CT scan kanker paru.
3. Citra CT scan kanker paru di crop menjadi ukuran 64x64 piksel agar mempermudah untuk pengolahan selanjutnya.

1.5 Manfaat Penelitian

Dengan menggunakan teknologi *deep learning*, penelitian ini diharapkan dapat membantu ahli medis dalam membaca hasil citra CT scan dengan cepat dan akurat melalui model *Attention U-Net* sehingga dapat mengoptimalkan pengambilan keputusan terindikasi kanker atau tidak.



Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA

BAB II

LANDASAN TEORI


2.1 Penyakit Kanker Paru

Penyakit kanker masih menjadi permasalahan yang serius di seluruh dunia. Salah satu penyakit kanker yang memiliki angka kematian tinggi yaitu kanker paru-paru. Kanker paru-paru adalah tumor paru-paru ganas yang ditandai dengan pertumbuhan sel-sel tidak terkendali di jaringan paru-paru. Penyakit ini umumnya disebabkan oleh polusi udara yang berasal dari lingkungan yang tidak baik akibat dari orang yang mengkonsumsi rokok sehingga paru-paru menjadi rawan terinfeksi oleh asap yang masuk ke dalam tubuh. Gejala dari kanker paru-paru diantaranya sesak napas, batuk, nyeri dada, perubahan suara, warna sputum berubah dan batuk darah [2].

Pemantauan terapi pengobatan penyakit kanker paru-paru menggunakan citra *computed tomography* (CT) scan adalah strategi penting untuk diagnosis kanker paru-paru dini [12]. Citra CT scan memberikan gambaran organ dalam paru-paru pasien. Hasil citra CT scan tersebut biasanya menunjukkan adanya benjolan berupa bintik-bintik kecil putih yang biasa disebut nodul. Para ahli medis akan menganalisa hasil citra CT scan dengan melihat karakteristik atau ciri khusus pada citra CT scan dan mengambil keputusan dari hasil tersebut.

2.2 Segmentasi Citra

Segmentasi citra merupakan proses membagi citra ke dalam beberapa objek berdasarkan kemiripan dari objek tersebut [4]. Pada citra yang mengandung hanya satu objek, objek dibedakan dari latar belakangnya. Segmentasi citra secara umum dibagi menjadi dua yaitu segmentasi semantik dan segmentasi instance. Segmentasi semantik merupakan segmentasi yang menyatukan beberapa objek yang identik ke dalam satu kelas yang sama menjadi satu segmen tanpa membedakan tiap-tiap individu objek [13]. Sedangkan segmentasi instance merupakan segmentasi yang memperlakukan beberapa objek dari kelas yang sama sebagai individu yang berbeda [13]. Contoh dari segmentasi semantik dan instance dapat dilihat pada Gambar 2.1



Gambar 2.1 Contoh (a) sampel gambar, (b) segmentasi semantik, dan (c) segmentasi instance [13].

2.3 Fungsi Aktivasi

Fungsi aktivasi adalah fungsi pada sebuah layer *neural network* yang digunakan untuk menghitung output dari nilai inputnya. Berikut ini adalah fungsi aktivasi yang digunakan:

2.3.1 Sigmoid

Sigmoid merupakan fungsi aktivasi yang memiliki kurva berbentuk ‘S’, dimana nilai output yang dihasilkan antara 0-1 [14]. Fungsi ini membantu dalam melakukan perhitungan yang ditafsirkan sebagai probabilitas [15]. Secara matematis, fungsi ini dirumuskan dalam persamaan 2.1 yaitu:

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.1)$$

2.3.2 Restricted Linear Unit (ReLU)

ReLU merupakan fungsi aktivasi populer dan banyak digunakan karena keefisiennya [14]. Fungsi ini secara umum memiliki batas bawah yaitu bilangan nol, yang berarti jika outputnya positif ($x > 0$) maka akan menghasilkan nilai yang sama ($x = x$) dan jika outputnya negatif ($x \leq 0$) maka akan menghasilkan nilai nol ($x = 0$) [16]. Secara matematis, fungsi ini dirumuskan pada persamaan 2.2 yaitu:

$$f(x) = \max(0, x) \quad (2.2)$$

2.4 Loss Function

Loss function adalah fungsi yang digunakan untuk mengevaluasi nilai parameter sebuah model, dimana fungsi tersebut berupaya untuk diminimalkan. Pada permasalahan medical segmentasi, *loss function* yang digunakan yaitu *Focal Tversky Loss*. Loss ini mengadaptasi *Tversky Loss* yang menggunakan *Tversky Index* (TI) dengan menerapkan parameter khusus berupa γ [17]. Parameter khusus ini mampu mengontrol antara *background* (latar belakang) dengan ROI yang kecil.

Tversky Index sendiri erat kaitannya dengan *Dice Coefficient*, dimana pada *False Positive* (FP) dan *False Negative* (FN) diberi bobot berbeda masing-masing dengan α dan β . Pemberian bobot berbeda ini berguna untuk meningkatkan nilai recall [18]. Dengan menggunakan *Tversky Index* (TI) pada persamaan 2.3, *Focal Tversky Loss* didefinisikan sebagai berikut pada persamaan 2.4

$$TI = \frac{\sum_{i=1}^N p_{ic} g_{ic} + \varepsilon}{\sum_{i=1}^N p_{ic} g_{ic} + \alpha \sum_{i=1}^N p_{i\bar{c}} g_{ic} + \beta \sum_{i=1}^N p_{ic} g_{i\bar{c}} + \varepsilon} \quad (2.3)$$

$$FTL = \sum_{c=1}^C (1 - TI)^{\frac{1}{\gamma}} \quad (2.4)$$

Dengan γ berkisar dari [1,3] dimana N adalah total piksel dalam gambar, C adalah himpunan kelas, p_{ic} adalah probabilitas piksel i dalam kelas lesi c , $p_{i\bar{c}}$ adalah probabilitas piksel i dalam kelas non lesi c , g_{ic} adalah *ground truth* dalam kelas lesi c , dan $g_{i\bar{c}}$ adalah *ground truth* dalam kelas non lesi c .


2.5 Adam optimizer

Adam optimizer adalah algoritma optimasi stokastik yang efisien yang hanya membutuhkan gradien orde pertama dengan sedikit kebutuhan memori. Metode ini mudah diterapkan, efisien secara komputasi, dan sangat cocok untuk permasalahan yang berkaitan dengan data dan parameter [19]. *Adam optimizer* juga merupakan algoritma penurunan gradient adaptif sehingga *learning rate*

dipertahankan per parameter atau dengan kata lain untuk masing-masing parameter *learning rate* disesuaikan.

2.6 U-Net

U-Net adalah salah satu metode dasar untuk permasalahan medical segmentasi yang dirancang oleh Olaf Ronneberger [20]. Arsitektur *U-Net* memiliki bentuk huruf “U” yang terdiri dari jalur *downsampling* dan *upsampling*. *U-Net* memiliki skip koneksi yang berfungsi untuk menggabungkan info spasial yang didapat di *downsampling* dengan *upsampling*. Arsitektur dasar *U-Net* disajikan pada Gambar 2.2



Gambar 2.2 Arsitektur *U-Net* [20].


Jalur *downsampling* terdiri dari dua lapisan konvolusi (3x3) berturut-turut diikuti oleh fungsi aktivasi ReLU dan satu lapisan *max pooling* (2x2) dengan *stride* dua. Pada proses *downsampling*, ukuran *feature map* dibagi dua sementara jumlah *feature map* digandakan dua kali lipat. Jalur *upsampling* terdiri dari satu lapisan *upsampling* (2x2), skip koneksi, dua lapisan konvolusi (3x3) berturut-turut dan satu tambahan konvolusi (1x1). Pada proses *upsampling* ukuran *feature map* digandakan dua kali lipat sementara jumlah *feature map* dibagi dua.

2.6.1 Lapisan Konvolusi

Lapisan konvolusi diadopsi di blok *downsampling* dan *upsampling* pada arsitektur *U-Net*. Pada lapisan konvolusi dilakukan operasi konvolusi berupa operasi perkalian antar elemen dari matriks input dan matriks kernel [15]. Output dari lapisan konvolusi disebut feature map. Persamaan dari operasi konvolusi dapat dilihat pada persamaan (2.5):

$$conv = \sum_{i=1}^r \sum_{j=1}^c K_{ij} I_{ij} \quad (2.5)$$

Dimana K mewakili matriks input area gambar yang dicakup oleh matriks kernel, I mewakili matriks kernel, serta r dan c mewakili jumlah baris dan kolom dari kedua matriks. Untuk menjaga ukuran output sama dengan ukuran input akan digunakan *padding* dan *stride* = 1. *Padding* merupakan penambahan ukuran piksel dengan nilai tertentu disekitar data input sedangkan *stride* merupakan parameter yang menentukan berapa jumlah pergeseran filter [21]. Ukuran output lapisan konvolusi bergantung pada ukuran input, *padding*, ukuran kernel dan *stride* seperti pada contoh Gambar 2.3




Gambar 2.3 Contoh ilustrasi operasi konvolusi [22].

2.6.2 Lapisan *pooling*

Lapisan *pooling* digunakan setelah lapisan konvolusi untuk mengurangi ukuran *feature map*. Salah satu metode lapisan *pooling* yaitu *max pooling*. Gambar 2.4 menunjukkan contoh *max pooling* dengan *stride* 2. *Max pooling* akan mengambil nilai maksimum pada wilayah *features map* yang dicakup oleh kernel


[23]. Setelah *feature map* melewati lapisan *max pooling*, lebar dan tinggi input akan berkurang setengah kali lipat dari ukuran awal.



Gambar 2.4 Contoh ilustrasi operasi *max pooling* [23].

2.6.3 Lapisan *upsampling*

Lapisan *upsampling* digunakan untuk meningkatkan ukuran *feature map*. Pada proses *upsampling*, setiap elemen dalam matriks input akan diulang dalam dua arah [23] seperti yang ditunjukkan pada Gambar 2.5. Setelah *feature map* melewati lapisan *upsampling*, lebar dan tinggi input akan meningkat dua kali lipat.



Gambar 2.5 Contoh ilustrasi operasi *upsampling* [23].

2.7 Metrik Evaluasi

Pengukuran terhadap kinerja model penting dilakukan untuk melihat seberapa baik model dalam melakukan tugas medical segmentasi. Metrik evaluasi yang digunakan untuk mengevaluasi tugas medical segmentasi yaitu dengan melakukan pengukuran nilai *dice coefficient*, *precision*, dan *recall*.

2.7.1 Dice Coefficient

Dice coefficient merupakan metrik evaluasi yang banyak digunakan dalam mengevaluasi kinerja medical segmentasi [24]. *Dice coefficient* mengukur tumpang tindih antara daerah yang tersegmentasi dengan *ground truth*. Formula *dice coefficient* dapat dilihat pada persamaan (2.6). Metrik ini memiliki kisaran nilai dari 0 – 1 , nilai 1 menunjukkan tumpang tindih yang sempurna antara prediksi dan *ground truth* sedangkan nilai 0 menunjukkan tidak ada tumpang tindih antara prediksi dan *ground truth*.

$$Dice\ Coefficient = \frac{2 \times |A \cap B|}{|A| + |B|} \quad (2.6)$$

Dimana *A* sebagai *ground truth* dan *B* sebagai hasil predict segmentasi dari model.

2.7.2 Precision dan Recall

Precision mengukur jumlah objek yang diprediksi benar oleh model dalam segmentasi yang dihasilkan [25]. Sementara *recall* mengukur jumlah objek yang sebenarnya ada dalam gambar (berdasarkan *ground truth*) berhasil ditemukan oleh model. Formula dari *precision* dan *recall* dapat dilihat pada persamaan (2.7) dan (2.8):

$$Precision = \frac{TP}{TP + FP} \quad (2.7)$$

$$Recall = \frac{TP}{TP + FN} \quad (2.8)$$

Precision dan *recall* dihitung menggunakan parameter TP, FP, dan FN. Oleh karena itu, nilai threshlod IoU digunakan untuk menghitung nilai TP, FP, dan FN [25]. Nilai IoU dapat dihitung dengan membandingkan daerah *ground truth* dan *predict* yang dapat ditulis dengan persamaan (2.9):

$$IoU = \frac{|A \cap B|}{|A \cup B|} \quad (2.9)$$

Misalkan ditetapkan nilai threshold IoU adalah 0.5, maka:

- Jika $IoU \geq 0.5$ maka dikategorikan sebagai TP (*True Positive*) atau daerah yang diprediksi dengan benar sebagai objek
- Jika $IoU < 0.5$ maka dikategorikan sebagai FP (*False Positive*) atau daerah yang seharusnya diprediksi sebagai objek tetapi salah diprediksi sebagai background oleh model
- Jika daerah yang seharusnya diprediksi sebagai background tetapi salah diprediksi sebagai objek oleh model maka dikategorikan sebagai FN (*False Negative*)




Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA

BAB III

METODOLOGI PENELITIAN

3.1 Sumber Data


Data yang digunakan pada penelitian ini adalah data sekunder yang diperoleh dari website *cancer imaging archive* [26]. Sumber data ini banyak digunakan oleh peneliti sebagai pengembangan metode CAD untuk segmentasi dan diagnosis kanker paru-paru. Data ini berupa citra CT scan LIDC-IDRI pasien kanker paru-paru, dimana setiap pasiennya menghasilkan beberapa irisan gambar CT scan. Data yang akan diolah hanya memakai irisan CT scan yang terdapat nodul saja yaitu berjumlah 1000 irisan CT scan kanker paru dan 1000 irisan masks kanker paru. Setiap irisan gambar CT scan menyediakan anotasi gambar atau masks yang telah dilakukan empat ahli radiologi toraks berpengalaman [26].



Gambar 3.1 Contoh Data (a) Ct Scan Kanker Paru dan (b) Masks Kanker Paru

3.2 Tahapan Penelitian

Sub bab ini berisikan tahapan penelitian yang akan dilakukan. Penulis menggunakan bahasa pemrograman *Python* versi 3.7.13 melalui google colab dengan bantuan beberapa modul diantaranya seperti *numpy*, *tensorflow*, *keras*, *matplotlib*. Selain itu penulis juga menggunakan aplikasi *Adobe Photoshop CS6* yang digunakan untuk memotong gambar area nodul kanker paru pada data CT Scan. Proses penelitian yang dilakukan dapat dilihat pada Gambar 3.2



Gambar 3.2 Alur Penelitian

3.2.1 Preprocessing Data

Sebelum mengolah data citra CT scan, terlebih dulu akan dilakukan proses awal yaitu *preprocessing* data. Tahapan *preprocessing* data ini bertujuan agar data citra CT scan sudah siap diolah ke tahapan selanjutnya. Dalam penelitian ini *preprocessing* yang dilakukan diantaranya adalah:

a. *Cropping*

Proses ini digunakan untuk membuang bagian citra yang tidak diperlukan sehingga dapat menambah fokus pada objek saat pengolahan. *Cropping* dilakukan terhadap data citra CT scan yang berukuran awal 512×512 piksel menjadi 64×64 piksel menggunakan *Adobe Photoshop CS6*.

b. Konversi RGB ke *grayscale*

Proses ini digunakan untuk mengkonversi seluruh citra CT scan RGB yang memiliki 3 channel (*Red, Green, Blue*) menjadi 1 channel (*Grayscale*).

c. Normalisasi

Proses ini digunakan untuk mentransformasi setiap nilai piksel menjadi sekumpulan nilai baru sehingga nilai mean akan mendekati 0 dan nilai standar deviasi akan mendekati 1.

d. Perbaikan Citra

Proses ini digunakan untuk meningkatkan kualitas citra CT scan dengan menghilangkan butiran-butiran warna yang mengganggu pada foto (*noise*) dengan median filter.

3.2.2 Pengaturan Hyperparameter

Setelah data siap diolah, selanjutnya perlu dilakukan pengaturan nilai *hyperparameter* untuk membuat model. Proses pengaturan nilai *hyperparameter* untuk mendapatkan model dengan performa optimal disebut *hyperparameter tuning*. Dalam penelitian ini, penulis akan mencari kombinasi nilai *hyperparameter* berdasarkan nilai *learning rate* dan *batch size* untuk menemukan kombinasi nilai *hyperparameter* optimal yang akan digunakan model. Semua

kombinasi dari nilai *hyperparameter* diuji untuk mendapatkan pilihan yang optimal [15]. Nilai *hyperparameter learning rate* dan *batch size* yang digunakan dalam penelitian ini sebagai berikut:

Tabel 3.1 Kombinasi Nilai *Hyperparameter Tuning*

<i>Hyperparameter</i>	Nilai
<i>Learning Rate</i>	(0.0001 ; 0.001 ; 0.01)
<i>Batch Size</i>	(8 ; 16 ; 32)

Dari Tabel 3.1 akan menghasilkan sembilan pasang kombinasi nilai *hyperparameter*, dimana masing-masing nilai tersebut diambil dari beberapa penelitian yang telah dilakukan dalam penelitian medical segmentasi [8][18][11]. Penelitian ini menggunakan *dice coefficient* sebagai metriknya sehingga kombinasi nilai *hyperparameter* yang menghasilkan nilai *dice coefficient* tertinggi yang akan terpilih sebagai nilai *hyperparameter* optimal untuk model.

3.2.3 Melatih Model


Setelah mengatur pemilihan nilai *hyperparameter*, akan dilakukan pembentukan arsitektur dari model yang digunakan. Sebelum itu, ditentukan terlebih dahulu *loss function* dan metode optimasi yang digunakan dalam penelitian. *Loss function* yang digunakan yaitu *Focal Tversky Loss* dengan memakai parameter dari penelitian sebelumnya [18] yaitu $\alpha = 0.7$, $\beta = 0.3$, dan $\gamma = \frac{4}{3}$ sementara metode optimasi yang digunakan yaitu *Adam Optimizer*.

Pembagian data pada penelitian ini untuk data train, data validasi dan data test berturut-turut yaitu 60%, 20%, dan 20%.

Arsitektur model yang digunakan dalam penelitian ini yaitu *Attention U-Net*. Model *Attention U-Net* adalah model yang hanya menyoroti aktivasi yang relevan selama pelatihan. Model ini dibangun dari arsitektur dasar *U-Net*, dimana pada setiap bagian skip koneksi *U-Net* diterapkan *attention gate*. Pada model *U-Net*, proses penggabungan info spasial atau skip koneksi membawa representasi fitur yang buruk karena pada lapisan awal representasi fitur cukup lemah. Oleh karena itu, peranan *attention gate* pada skip koneksi *U-Net* untuk memberi bobot lebih


pada fitur yang menarik sehingga mampu menyoroti fitur-fitur yang menonjol [11].

Arsitektur model *Attention U-Net* yang digunakan berdasarkan penelitian sebelumnya [11] dengan memakai jumlah saluran (16,32,64,128,256) dan akan membandingkannya dengan model *U-Net* dasar. Ilustrasi proses pelatihan model *Attention U-Net* dapat dilihat pada Gambar 3.3



Gambar 3.3 Arsitektur *Attention U-Net* [11].

Proses pelatihan model *Attention U-Net* dimulai dari input gambar berupa CT scan paru akan melewati jalur *downsampling* yang terdiri dari dua lapisan konvolusi (3×3) berturut-turut diikuti oleh ReLU dan satu lapisan *max pooling* (2×2) dengan *stride* dua. Pada proses *downsampling*, ukuran *feature maps* dibagi dua sementara jumlah *feature maps* digandakan dua kali lipat. Input awal pada penelitian ini memiliki ukuran $64 \times 64 \times 1$ setelah melewati jalur *downsampling* ukurannya berubah seterusnya secara bertahap sampai lapisan paling bawah menjadi $4 \times 4 \times 256$. Setelah melewati jalur *downsampling*, input terlebih dahulu akan melewati *attention gate* yang diterapkan pada setiap skip koneksi sebelum lanjut melewati jalur *upsampling*. Skema *attention gate* dapat dilihat pada Gambar 3.4



Gambar 3.4 Skema Alur Kerja *Attention Gate* [11].

Penjelasan skema kerja *attention gate* pada Gambar 3.4 adalah sebagai berikut:

1. *Attention gate* memiliki dua input berupa x dan g.
 - Input g berasal dari lapisan jaringan yang paling bawah. Input ini digunakan sebagai sinyal gating untuk meningkatkan pembelajaran input x karena memiliki representasi fitur lebih baik dan berasal dari jaringan yang lebih dalam.
 - Input x berasal dari skip koneksi atau lapisan sebelumnya yang memiliki info spasial lebih baik tetapi tidak banyak info fitur.
2. Selanjutnya dilakukan proses penggabungan input x dan input g.
3. Kemudian hasil penggabungan input x dan input g akan melewati lapisan ReLU ($\sigma_1(x) = \max(0, x)$) untuk aktivasi dan melewati konvolusi 1x1.
4. Lalu input ini melewati lapisan sigmoid ($\sigma_2(x) = \frac{1}{1+e^{-x}}$) yang akan menskalakan bobot input diantara rentang $[0,1]$ yang menghasilkan koefisien *attention* (α).
5. Saat sudah memiliki kisaran bobot input $[0,1]$ selanjutnya akan dilakukan *Resampler* atau pengambilan sampel ulang untuk membuat ukurannya sama dengan ukuran x asli.
6. Kalikan koefisien *attention* (α) dan vektor x asli dengan elemen-wise untuk mendapatkan output dari *attention gate*.

Output *attention gate* akan melewati jalur *upsampling*. Jalur ini terdiri dari satu lapisan *upsampling* (2×2), skip koneksi, dua lapisan konvolusi (3×3) berturut-turut dan satu tambahan konvolusi (1×1) untuk menghasilkan gambar yang tersegmentasi. Pada proses *upsampling*, ukuran *feature maps* digandakan

dua kali lipat sementara jumlah *feature maps* dibagi dua. Ukuran dari output *attention gate* $8 \times 8 \times 128$ akan berubah seterusnya secara bertahap sampai lapisan paling atas menjadi $64 \times 64 \times 1$. Pelatihan pada penelitian ini menggunakan *4-fold cross validation*, dimana dilakukan pelatihan sebanyak empat kali dengan 30 epoch pada setiap model dan model yang memiliki nilai *loss* terkecil pada data validasi akan disimpan.

3.2.4 Evaluasi Setiap Model

Model yang sudah dilatih kemudian akan dievaluasi. Pada penelitian ini dilakukan evaluasi pada setiap model menggunakan pengukuran *dice coefficient*, *recall*, dan *precision* untuk melihat seberapa baik performa setiap model dalam mensegmentasi nodul kanker paru-paru. Kemudian dari hasil evaluasi tersebut akan dilihat kehadiran *attention gate* pada model *U-Net* apakah memberikan kinerja lebih baik dibandingkan model *U-Net*.

3.2.5 Hasil Segmentasi Gambar Nodul Setiap Model


Setelah dilakukan evaluasi, masing-masing model akan memberikan hasil segmentasi gambar nodul kanker paru-paru yang akan dibandingkan dengan *ground truth*, semakin mirip dengan *ground truth* maka akan semakin baik. Kemudian dari hasil segmentasi gambar tersebut akan dilihat kehadiran *attention gate* pada model *U-Net* apakah mampu memberikan fokus lebih pada objek yang disegmentasi dibandingkan dengan model *U-Net*.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil *Preprocessing* Data

Data citra CT scan kanker paru terlebih dahulu dilakukan proses *preprocessing* data sebelum diolah. Proses *preprocessing* data dilakukan seperti Gambar 4.1 dengan melakukan *cropping* terhadap data citra CT scan kanker paru yang berukuran awal 512×512 piksel menjadi 64×64 piksel, lalu seluruh citra yang memiliki 3 channel (RGB) diubah menjadi 1 channel (*Grayscale*). Selanjutnya citra akan dinormalisasi dengan mentransformasi setiap nilai piksel dengan *mean* dan standar deviasi pada keseluruhan citra sehingga data baru akan memiliki *mean* ≈ 0 dan variansi ≈ 1 . Kemudian terakhir dilanjutkan dengan menghilangkan butiran-butiran warna yang mengganggu pada citra menggunakan median filter untuk meningkatkan kualitas citra.




Gambar 4.1 Proses *Preprocessing* Data

4.2 Hasil *Hyperparameter Tuning*

Proses *hyperparameter tuning* dilakukan dengan menguji semua kombinasi *hyperparameter* berdasarkan nilai *learning rate* dan *batch size* yang menghasilkan hasil paling optimal. Nilai *learning rate* dan *batch size* yang digunakan masing-masing adalah (0.0001; 0.001; 0.01) dan (8; 16; 32). Penelitian ini menggunakan model *Attention U-Net* dan model *U-Net* sebagai model pembanding sehingga akan dilakukan proses *hyperparameter tuning* terhadap dua model tersebut.

4.2.1 Hasil Hyperparameter Tuning Model Attention U-Net

Pada model *Attention U-Net*, proses *hyperparameter tuning* menggunakan *dice coefficient* sebagai metrik. Hasil *hyperparameter tuning* pada model *Attention U-Net* dapat dilihat pada Gambar 4.2 yang divisualisasikan melalui *parallel coordinates plot*.




Gambar 4.2 Plot Hasil *Hyperparameter Tuning* Model *Attention U-Net*

Berdasarkan Gambar 4.2 terlihat bahwa terdapat sembilan kombinasi dari nilai *learning rate* dan *batch size* yang dihasilkan. Kombinasi nilai *learning rate* sebesar 0.01 dan *batch size* sebesar 16 menghasilkan nilai *dice coefficient* tertinggi sehingga kombinasi tersebut terpilih sebagai *hyperparameter* yang paling optimal pada model *Attention U-Net*.

4.2.2 Hasil Hyperparameter Tuning Model U-Net

Pada model *U-Net*, proses *hyperparameter tuning* menggunakan *dice coefficient* sebagai metrik. Hasil *hyperparameter tuning* pada model *U-Net* dapat dilihat pada Gambar 4.3 yang divisualisasikan melalui *parallel coordinates plot*.



Gambar 4.3 Plot Hasil *Hyperparameter Tuning* Model *U-Net*


Berdasarkan Gambar 4.3 terlihat bahwa terdapat sembilan kombinasi dari ukuran *learning rate* dan *batch size* yang dihasilkan. Kombinasi ukuran *learning rate* sebesar 0.001 dan *batch size* sebesar 8 menghasilkan nilai *dice coefficient* tertinggi sehingga kombinasi tersebut terpilih sebagai *hyperparameter* yang paling optimal pada model *U-Net*.

4.3 Hasil Melatih Model

Pelatihan pada penelitian ini menggunakan *4-fold cross validation*, dimana dilakukan pelatihan sebanyak empat kali dengan 30 epoch pada setiap model. *loss function* yang digunakan berupa *Focal Tversky Loss*. Proses pelatihan dilakukan menggunakan model *Attention U-Net* dan model *U-Net* sebagai model pembandingan. Model yang memiliki nilai *loss* terendah merupakan model yang memiliki tingkat kesalahan terkecil.

4.3.1 Hasil Melatih Model *Attention U-Net*

Pelatihan pada model *Attention U-Net* menggunakan *hyperparameter* optimal pada subbab sebelumnya yaitu *learning rate* sebesar 0.01 dan *batch size* sebesar 16. Hasil training pada model *Attention U-Net* dapat dilihat pada Gambar 4.4 dalam grafik *loss* yang mengalami perubahan nilai *loss* pada data train dan val untuk setiap epochnya.



Gambar 4.4 Plot Nilai *Loss* Model *Attention U-Net* pada (a) data train dan (b) data val


Berdasarkan Gambar 4.4 terlihat bahwa pada data train, *fold-1* didapatkan nilai loss minimum sebesar 0.0847 pada epoch ke-30. Pada *fold-2* didapatkan nilai loss minimum sebesar 0.0937 pada epoch ke-30 serta pada *fold-3* didapatkan nilai loss minimum sebesar 0.0967 pada epoch ke-30 dan pada *fold-4* didapatkan nilai loss minimum sebesar 0.0820 pada epoch ke-30.

Sedangkan pada data val, *fold-1* loss minimum yang didapatkan sebesar 0.1080 pada epoch ke-25. Pada *fold-2* didapatkan nilai loss minimum sebesar 0.1150 pada epoch ke-26 serta pada *fold-3* didapatkan nilai loss minimum sebesar 0.1213 pada epoch ke-28 dan pada *fold-4* didapatkan nilai loss minimum sebesar 0.1095 pada epoch ke-26.

Setelah mendapatkan nilai *loss* minimum, grafik *loss* model *Attention U-Net* terus mengalami penurunan hingga konvergen pada akhir epoch. Model yang dilatih dengan *hyperparameter* yang tepat akan membuat grafik *loss* terus menurun menuju nilai yang kecil atau dengan kata lain model akan memiliki tingkat kesalahan kecil.

4.3.2 Hasil Melatih Model *U-Net*

Pelatihan pada model *U-Net* menggunakan *hyperparameter* optimal pada subbab sebelumnya yaitu *learning rate* sebesar 0.001 dan *batch size* sebesar 8. Hasil training pada model *U-Net* dapat dilihat pada Gambar 4.5 dalam grafik *loss* yang mengalami perubahan nilai *loss* pada data train dan val untuk setiap epochnya.



Gambar 4.5 Plot Nilai Loss Model *U-Net* pada (a) data train dan (b) data val

Berdasarkan Gambar 4.5 terlihat bahwa pada data train, *fold-1* didapatkan nilai loss minimum sebesar 0.0909 pada epoch ke-27. Pada *fold-2* didapatkan nilai loss minimum sebesar 0.0967 pada epoch ke-30 pada *fold-3* didapatkan nilai loss minimum sebesar 0.1003 pada epoch ke-20 serta dan pada *fold-4* didapatkan nilai loss minimum sebesar 0.0968 pada epoch ke-18.

Sedangkan pada data val, *fold-1* loss minimum yang didapatkan sebesar 0.1092 pada epoch ke-29. Pada *fold-2* didapatkan nilai loss minimum sebesar 0.1190 pada epoch ke-28 serta pada *fold-3* didapatkan nilai loss minimum sebesar 0.1156 pada epoch ke-19 dan pada *fold-4* didapatkan nilai loss minimum sebesar 0.1203 pada epoch ke-25.

Setelah mendapatkan nilai *loss minimum*, grafik *loss model U-Net* terus mengalami penurunan hingga konvergen pada akhir epoch. Model yang dilatih dengan *hyperparameter* yang tepat akan membuat grafik *loss* terus menurun menuju nilai yang kecil atau dengan kata lain model akan memiliki tingkat kesalahan kecil.

4.4 Hasil Evaluasi Setiap Model

Hasil performa dari setiap model berdasarkan nilai *dice coefficient*, *recall*, dan *precision* disajikan pada Tabel 4.1

Tabel 4.1 Hasil Evaluasi Setiap Model

Model	<i>Dice Coefficient</i>	<i>Recall</i>	<i>Precision</i>
<i>Attention U-Net</i>	0.9415	0.9821	0.9771
<i>U-Net</i>	0.9297	0.9783	0.9758

Seperti yang terlihat pada Tabel 4.1 performa model *Attention U-Net* berhasil mengungguli performa dari model *U-Net* dengan memperoleh hasil nilai *dice coefficient*, *recall*, dan *precision* masing-masing sebesar 0.9415 ; 0.9821 ; 0.9771. Hasil ini menunjukkan bahwa penambahan *attention gate* pada skip koneksi *U-Net* mampu meningkatkan performa model *Attention U-Net* dalam mensegmentasi nodul kanker paru-paru dibandingkan dengan model *U-Net*.

4.5 Hasil Segmentasi Gambar Setiap Model

Hasil segmentasi gambar nodul kanker paru-paru dari setiap model dapat dilihat pada Gambar 4.6



Gambar 4.6 Perbandingan Hasil Segmentasi Gambar Nodul Kanker Paru-Paru Setiap Model dengan Image CT Scan Nodul Kanker Paru-Paru dan Ground Truth

Pada Gambar 4.6 terlihat bahwa rata-rata hasil segmentasi gambar nodul kanker paru-paru model *Attention U-Net* mengungguli hasil dari model *U-Net* dengan memiliki kemiripan lebih terhadap *ground truth*. Hasil ini menunjukkan bahwa penambahan *attention gate* pada skip koneksi *U-Net* mampu menyoroti bagian-bagian yang menonjol dan lebih fokus terhadap objek yang disegmentasi dibandingkan dengan model *U-Net*.



BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan data dan hasil penelitian yang telah dilakukan dapat disimpulkan bahwa:

1. Kombinasi nilai *hyperparameter learning rate* sebesar 0.01 dan *batch size* sebesar 16 menjadi nilai *hyperparameter* yang paling optimal untuk model *Attention U-Net* dalam mensegmentasi nodul kanker paru. Sementara kombinasi nilai *hyperparameter learning rate* sebesar 0.001 dan *batch size* sebesar 8 menjadi nilai *hyperparameter* paling optimal untuk model *U-Net*.
2. Performa model *Attention U-Net* berhasil mengungguli performa model *U-Net* dengan memperoleh hasil nilai *dice coefficient*, *recall*, dan *precision* masing-masing sebesar 0.9415 ; 0.9821 ; 0.9771.
3. Hasil segmentasi gambar nodul kanker paru-paru model *Attention U-Net* memiliki kemiripan lebih dengan *ground truth*. Hasil ini menunjukkan bahwa penambahan *attention gate* pada skip koneksi *U-Net* mampu meningkatkan performa dan mampu menyoroti bagian-bagian yang menonjol serta lebih fokus terhadap objek yang disegmentasi dibandingkan dengan model *U-Net*.

5.2 Saran

Penelitian ini masih memiliki banyak kekurangan, sehingga perlu diperbaiki dan dikembangkan untuk penelitian selanjutnya. Oleh karena itu, terdapat beberapa saran yang dapat diberikan penulis yaitu:

1. Dapat mengukur luas area diameter nodul agar nantinya bisa diklasifikasikan ke dalam jenis nodul yang berbeda seperti benigna dan maligna.
2. Dapat menambahkan penyetelan *hyperparameter* lainnya seperti penggunaan optimizer yang berbeda (Adam, RMSprop) dan penambahan regularisasi (dropout).

REFERENSI

- [1] “World Health Organization, cancer.” <https://www.who.int/news-room/fact-sheets/detail/cancer> (accessed Mar. 08, 2021).
- [2] P. M. Shakeel, M. A. Burhanuddin, and M. I. Desa, “Lung cancer detection from CT image using improved profuse clustering and deep learning instantaneously trained neural networks,” *Meas. J. Int. Meas. Confed.*, vol. 145, pp. 702–712, 2019.
- [3] Z. Xiao, B. Liu, L. Geng, F. Zhang, and Y. Liu, “Segmentation of lung nodules using improved 3D-UNet neural network,” *Symmetry (Basel)*, vol. 12, no. 11, pp. 1–15, 2020.
- [4] F. D. Marleny, *Mengenai Pengolahan Citra Digital menggunakan Python*, no. January. 2021.
- [5] S. J. Yoo *et al.*, “Automated lung segmentation on chest computed tomography images with extensive lung parenchymal abnormalities using a deep neural network,” *Korean J. Radiol.*, vol. 22, no. 3, pp. 476–488, 2021.
- [6] Y. Kurata *et al.*, “Automatic segmentation of the uterus on MRI using a convolutional neural network,” *Comput. Biol. Med.*, vol. 114, no. August, p. 103438, 2019.
- [7] H. M. Saleh, N. H. Saad, and N. A. M. Isa, “Overlapping chromosome segmentation using U-Net: Convolutional networks with test time augmentation,” *Procedia Comput. Sci.*, vol. 159, pp. 524–533, 2019.
- [8] P. H. Prastyo, A. S. Sumi, and A. Nuraini, “Optic Cup Segmentation using U-Net Architecture on Retinal Fundus Image,” *JITCE (Journal Inf. Technol. Comput. Eng.)*, vol. 4, no. 02, pp. 105–109, 2020.
- [9] Y. Li *et al.*, “Lightweight U-Net For Lesion Segmentation In Ultrasound Images,” pp. 611–615, 2021.
- [10] J. Schlemper *et al.*, “Attention gated networks: Learning to leverage salient regions in medical images,” *Med. Image Anal.*, vol. 53, pp. 197–207, 2019.
- [11] O. Oktay *et al.*, “Attention U-Net: Learning Where to Look for the Pancreas,” no. Midl, 2018.
- [12] S. Wang *et al.*, “Central focused convolutional neural networks: Developing a data-driven model for lung nodule segmentation,” *Med. Image Anal.*, vol. 40, pp. 172–183, 2017.
- [13] A. B. Pratama, R. E. Abdul Kadir, and M. A. Hady, “Deteksi Ruang Kosong pada Jalan Menggunakan Semantic Segmentation pada Mobil

- Otonom,” *J. Tek. ITS*, vol. 11, no. 1, 2022, doi: 10.12962/j23373539.v11i1.81667.
- [14] H. Shaziya, K. Shyamala, and R. Zaheer, “Automatic Lung Segmentation on Thoracic CT Scans Using U-Net Convolutional Network,” *Proc. 2018 IEEE Int. Conf. Commun. Signal Process. ICCSP 2018*, no. April, pp. 643–647, 2018.
 - [15] E. Alpaydin, *Neural Networks and Deep Learning*. 2021.
 - [16] J. Moolayil, *Learn Keras for Deep Neural Networks: A Fast-Track Approach to Modern Deep Learning with Python*. 2019.
 - [17] M. Yeung, E. Sala, C. B. Schönlieb, and L. Rundo, “Unified Focal loss: Generalising Dice and cross entropy-based losses to handle class imbalanced medical image segmentation,” *Comput. Med. Imaging Graph.*, vol. 95, no. May, 2022.
 - [18] N. Abraham and N. M. Khan, “A novel focal tversky loss function with improved attention u-net for lesion segmentation,” in *Proceedings - International Symposium on Biomedical Imaging*, 2019, pp. 683–687.
 - [19] D. P. Kingma and J. L. Ba, “Adam: A method for stochastic optimization,” *3rd Int. Conf. Learn. Represent. ICLR 2015 - Conf. Track Proc.*, pp. 1–15, 2015.
 - [20] T. Ronneberger, Olaf; Fischer, Philipp; Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” pp. 234–241, 2015.
 - [21] D. D. Affifah, Y. Permanasari, and Respitawulan, “Bandung Conference Series: Mathematics Teknik Konvolusi pada Deep Learning untuk Image Processing,” *Bandung Conf. Ser. Math.*, vol. 02, no. 2, pp. 103–112, 2022, [Online]. Available: <https://doi.org/10.29313/bcsm.v2i2.4527>
 - [22] A. Ramos-Michel, M. Pérez-Cisneros, E. Cuevas, and D. Zaldivar, “Image Classification with Convolutional Neural Networks,” *Stud. Comput. Intell.*, vol. 967, no. November 2022, pp. 445–473, 2021, doi: 10.1007/978-3-030-70542-8_18.
 - [23] J. Shi *et al.*, “Improvement of damage segmentation based on pixel-level data balance using vgg-unet,” *Appl. Sci.*, vol. 11, no. 2, pp. 1–17, 2021, doi: 10.3390/app11020518.
 - [24] T. Zhou, S. Canu, and S. Ruan, “Automatic COVID-19 CT segmentation using U-Net integrated spatial and channel attention mechanism,” *Int. J. Imaging Syst. Technol.*, vol. 31, no. 1, pp. 16–27, 2021.
 - [25] M. T. Anam, “Evaluate Machine Learning Model to Better Understand Cutting in Wood,” 2021, [Online]. Available:

<http://urn.kb.se/resolve?urn=urn:nbn:se:uu:diva-448713>

- [26] “Cancer Imaging Archive, Collections, LIDC-IDRI.”
<https://public.cancerimagingarchive.net/nbia-search/> (accessed Mar. 11, 2021).



Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA