



PROPOSAL TUGAS AKHIR - SS234862

**PENANGANAN KETIDAKSEIMBANGAN DATA
MENGUNAKAN *WASSERSTEIN GENERATIVE
ADVERSARIAL NETWORK* DENGAN *GRADIENT
PENALTY* (WGAN-GP) UNTUK KLASIFIKASI CITRA
CHEST X-RAY PENYAKIT INFEKSI PARU**

PUTRI HANNA NARESWARI

NRP 5003221082

Dosen Pembimbing

Dr. Dra. Kartika Fithriasari, M.Si.

NIP 19691212 199303 2 002

Program Studi Sarjana Statistika

Departemen Statistika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2026



FINAL PROJECT PROPOSAL - SS234862

**HANDLING DATA IMBALANCE USING WASSERSTEIN
GENERATIVE ADVERSARIAL NETWORK WITH
GRADIENT PENALTY (WGAN-GP) FOR CHEST X-RAY
IMAGE CLASSIFICATION OF PULMONARY INFECTIOUS
DISEASES**

PUTRI HANNA NARESWARI

NRP 5003221082

Advisor

Dr. Dra. Kartika Fithriasari, M.Si.

NIP 19691212 199303 2 002

Bachelor Program of Statistics

Department of Statistics

Faculty of Science and Data Analytics

Institut Teknologi Sepuluh Nopember

Surabaya

2026

LEMBAR PENGESAHAN

PENANGANAN KETIDAKSEIMBANGAN DATA MENGGUNAKAN *WASSERSTEIN GENERATIVE ADVERSARIAL NETWORK* DENGAN *GRADIENT PENALTY* (WGAN-GP) UNTUK KLASIFIKASI CITRA *CHEST X-RAY* PENYAKIT INFEKSI PARU

PROPOSAL TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Statistika pada
Program Studi Sarjana Statistika
Departemen Statistika
Fakultas Sains dan Analitika Data
Institut Teknologi Sepuluh Nopember

Oleh: **PUTRI HANNA NARESWARI**
NRP 5003221082

Disetujui oleh:

Pembimbing:

- | | | |
|----|---|------------|
| 1. | <u>Dr. Dra. Kartika Fithriasari, M.Si.</u>
NIP 19691212 199303 2 002 | Pembimbing |
|----|---|------------|

Penguji:

- | | | |
|----|--------------------------------------|---------|
| 2. | <u>Nama dan gelar penguji</u>
NIP | Penguji |
| 3. | <u>Nama dan gelar penguji</u>
NIP | Penguji |

SURABAYA

<Bulan>, <Tahun>

(Halaman ini sengaja dikosongkan)

APPROVAL SHEET

Handling Data Imbalance Using Wasserstein Generative Adversarial Network with Gradient Penalty (WGAN-GP) for Chest X-Ray Image Classification of Pulmonary Infectious Diseases

FINAL PROJECT PROPOSAL

Submitted to fulfill one of the requirements
For obtaining a degree Bachelor of Statistics at
Bachelor Program of Statistics
Department of Statistics
Faculty of Science and Data Analytics
Institut Teknologi Sepuluh Nopember

By: **PUTRI HANNA NARESWARI**
NRP 5003221082

Approved By:
Advisor:

- | | | |
|----|---|---------|
| 1. | <u>Dr. Dra. Kartika Fithriasari, M.Si.</u>
NIP 19691212 199303 2 002 | Advisor |
|----|---|---------|

Examiners:

- | | | |
|----|---|----------|
| 2. | <u>Name of examiner and academic title</u>
NIP | Examiner |
| 3. | <u>Name of examiner and academic title</u>
NIP | Examiner |

SURABAYA

<Month>, <Year>

(Halaman ini sengaja dikosongkan)

PERNYATAAN ORISINALITAS

Yang bertanda tangan dibawah ini:

Nama Mahasiswa/NRP : Putri Hanna Nareswari/5003221082
Departemen : Statistika
Dosen Pembimbing/NIP : Dr. Dra. Kartika Fithriasari, M.Si./196912121993032002

Dengan ini menyatakan bahwa Tugas Akhir dengan judul “Penanganan Ketidakseimbangan Data Menggunakan *Wasserstein Generative Adversarial Network* dengan *Gradient Penalty* (WGAN-GP) untuk Klasifikasi Citra *Chest X-Ray* Penyakit Infeksi Paru” adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Surabaya,

Mengetahui
Dosen Pembimbing

Mahasiswa

(Dr. Dra. Kartika Fithriasari, M.Si.)
NIP 19691212 199303 2 002

(Putri Hanna Nareswari)
NRP 5003221082

(Halaman ini sengaja dikosongkan)

STATEMENT OF ORIGINALITY

The undersigned below:

Student's Name/NRP : Putri Hanna Nareswari/5003221082
Departement : Statistics
Advisor : Dr. Dra. Kartika Fithriasari, M.Si./196912121993032002.

Hereby declare that the Final Project with the title of “Handling Data Imbalance Using Wasserstein Generative Adversarial Network with Gradient Penalty (WGAN-GP) for Chest X-Ray Image Classification of Pulmonary Infectious Diseases” is the result of my own work, is original, and is written by following the rules of scientific writing.

If in the future there is a discrepancy with this statement, then I am willing to accept sanctions in accordance with the provisions that apply at Institut Teknologi Sepuluh Nopember.

Surabaya,

Acknowledged
Advisor

Student

(Dr. Dra. Kartika Fithriasari, M.Si.)
NIP 19691212 199303 2 002

(Putri Hanna Nareswari)
NRP 5003221082

(Halaman ini sengaja dikosongkan)

ABSTRAK

PENANGANAN KETIDAKSEIMBANGAN DATA MENGGUNAKAN *WASSERSTEIN GENERATIVE ADVERSARIAL NETWORK* DENGAN *GRADIENT PENALTY* (WGAN-GP) UNTUK KLASIFIKASI CITRA *CHEST X-RAY* PENYAKIT INFEKSI PARU

Nama Mahasiswa / NRP : Putri Hanna Nareswari / 5003221082
Prodi, Departemen : Sarjana Statistika, Departemen Statistika FSAD ITS
Dosen Pembimbing : Dr. Dra. Kartika Fithriasari, M.Si.

Abstrak

Deteksi dini dan klasifikasi jenis infeksi paru yang akurat sangat penting untuk menentukan penanganan medis yang tepat bagi pasien. Namun, ketidakseimbangan distribusi data antarkelas merupakan permasalahan krusial dalam klasifikasi citra medis yang dapat menyebabkan bias pada model, terutama dalam membedakan etiologi pneumonia pada citra *Chest X-ray*. Penelitian ini bertujuan untuk mengatasi masalah ketidakseimbangan data pada klasifikasi empat kelas penyakit infeksi paru (Normal, COVID-19, Pneumonia Bakterial, dan Pneumonia Viral) dengan mengintegrasikan *Wasserstein Generative Adversarial Network with Gradient Penalty* (WGAN-GP) dan arsitektur *transfer learning* ResNet-50. WGAN-GP digunakan sebagai metode augmentasi data generatif untuk membangkitkan citra sintetis pada kelas minoritas, khususnya pneumonia viral yang sering kali memiliki *F1-score* rendah akibat keterbatasan sampel dan kemiripan karakteristik visual dengan pneumonia bakterial. Kualitas citra sintetis yang dihasilkan dievaluasi menggunakan metrik *Frechet Inception Distance* (FID) dan *Structural Similarity Index Measure* (SSIM). Selanjutnya, pengaruh penggunaan data sintetis terhadap kinerja klasifikasi diuji menggunakan ResNet-50. Hasil penelitian diharapkan dapat menunjukkan bahwa penyeimbangan distribusi data menggunakan WGAN-GP mampu meningkatkan performa model secara signifikan, yang diukur melalui metrik *accuracy*, *precision*, *sensitivity*, dan *F1-score*. Penelitian ini memberikan kontribusi dalam pengembangan sistem deteksi dini penyakit infeksi paru yang lebih akurat dan stabil terhadap variasi jumlah data.

Kata kunci: *Ketidakseimbangan Data, WGAN-GP, ResNet-50, Chest X-ray, Infeksi Paru.*

(Halaman ini sengaja dikosongkan)

ABSTRACT

Handling Data Imbalance Using Wasserstein Generative Adversarial Network with Gradient Penalty (WGAN-GP) for Chest X-Ray Image Classification of Pulmonary Infectious Diseases

Student Name / NRP : Putri Hanna Nareswari / 5003221082
Program, Department : Bachelor Program of Statistics,
Department of Statistics F-Scientics ITS
Advisor : Dr. Dra. Kartika Fithriasari, M.Si.

Abstract

Accurate early detection and classification of pulmonary infections are essential to ensure proper medical treatment for patients. However, data imbalance across classes is a critical issue in medical image classification that can lead to model bias, particularly in distinguishing pneumonia etiologies on Chest X-ray (CXR) images. This study aims to address the data imbalance problem in the four-class classification of pulmonary infectious diseases (Normal, COVID-19, Bacterial Pneumonia, and Viral Pneumonia) by integrating Wasserstein Generative Adversarial Network with Gradient Penalty (WGAN-GP) and the ResNet-50 transfer learning architecture. WGAN-GP is used as a generative data augmentation method to generate synthetic images for minority classes, specifically viral pneumonia, which often has a low F1-score due to limited samples and visual similarities with bacterial pneumonia. The quality of the generated synthetic images is evaluated using Frechet Inception Distance (FID) and Structural Similarity Index Measure (SSIM). Furthermore, the impact of using synthetic data on classification performance is tested using ResNet-50. The results are expected to show that balancing the data distribution using WGAN-GP can significantly improve model performance, measured through accuracy, precision, sensitivity, and F1-score. This research contributes to the development of early detection systems for pulmonary infectious diseases that are more accurate and stable against variations in data volume.

Keywords: *Data Imbalance, WGAN-GP, ResNet-50, Chest X-ray, Pulmonary Infection.*

(Halaman ini sengaja dikosongkan)

KATA PENGANTAR

Puji dan syukur penulis panjatkan kehadiran Allah SWT yang telah melimpahkan Rahmat dan karunia-Nya sehingga penulisan Proposal Tugas Akhir dengan judul “Penanganan Ketidakseimbangan Data Menggunakan *Wasserstein Generative Adversarial Network* dengan *Gradient Penalty* (WGAN-GP) untuk Klasifikasi Citra *Chest X-Ray* Penyakit Infeksi Paru” dapat terselesaikan dengan baik dan tepat waktu. Penyusunan Proposal Tugas Akhir ini dapat diselesaikan bukan tanpa bantuan serta dukungan dari berbagai pihak. Oleh karena itu, penulis ingin menyampaikan rasa terima kasih kepada:

1. Ayah Agus Gatot Raharjo, Mama Suprpti, dan segenap keluarga besar Soekadi dan Sarjono, atas segala doa yang tidak pernah putus, kasih sayang tulus, serta pengorbanan luar biasa yang senantiasa menjadi kekuatan dan motivasi utama bagi penulis dalam menyelesaikan masa studi ini.
2. Bapak Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si. selaku Kepala Departemen Statistika ITS, Ibu Dr. Wibawati, S.Si., M.Si. selaku Sekretaris Departemen, serta Ibu Shofi Andari, S.Stat., M.Si., Ph.D. selaku Kepala Program Studi Statistika, atas ilmu, fasilitas, dan dukungan yang diberikan selama proses studi di Departemen Statistika ITS.
3. Ibu Dr. Dra. Kartika Fithriasari, M.Si. selaku dosen pembimbing, atas kesabaran, arahan, dan motivasi yang sangat berharga dalam membimbing penulis merencanakan serta menyusun proposal Tugas Akhir ini.
4. Ibu Dr. Santi Wulan Purnami, S.Si., M.Si. selaku dosen wali, yang telah memberikan bimbingan dan arahan akademik selama masa perkuliahan di Departemen Statistika ITS.
5. Seluruh Dosen Departemen Statistika ITS atas ilmu yang telah dibagikan selama masa perkuliahan, serta staf dan karyawan Departemen Statistika ITS yang telah membantu kelancaran urusan administratif penulis.
6. Gadin, Tessa, Alya, Afi, dan Eva, selaku orang yang sangat berarti bagi penulis yang selalu menjadi pendengar keluh kesah penulis baik sejak dahulu hingga masa perkuliahan, dan sudah tetap menjadi teman terbaik penulis di segala kondisi penulis.
7. Ara, Zelika, Ditha, Nayla, Maul, Iqbal, Bayu, Caca, Rizal, dan Yansen, atas kebersamaan, keceriaan, dan dukungan semangat yang luar biasa selama masa perkuliahan.
8. Teman-teman SMAN 2 Madiun, Statistika ITS 2022 “Antares”, serta seluruh pihak yang telah memberikan dukungan baik secara langsung maupun tidak langsung yang tidak dapat penulis sebutkan satu per satu.

Penulis menyadari bahwa proposal Tugas Akhir ini masih jauh dari sempurna. Oleh karena itu, segala kritik dan saran yang membangun sangat diharapkan demi perbaikan di masa mendatang.

(Halaman ini sengaja dikosongkan)

DAFTAR ISI

LEMBAR PENGESAHAN	i
APPROVAL SHEET	iii
PERNYATAAN ORISINALITAS	v
STATEMENT OF ORIGINALITY	vii
ABSTRAK	ix
ABSTRACT	xi
KATA PENGANTAR	xiii
DAFTAR ISI	xiv
DAFTAR GAMBAR	xvii
DAFTAR TABEL	xix
DAFTAR NOTASI	xxi
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan	2
1.4 Manfaat	3
1.5 Batasan Masalah	3
BAB 2 TINJAUAN PUSTAKA	5
2.1 Hasil Penelitian Terdahulu	5
2.2 Penyakit Infeksi Paru	6
2.2.1 COVID-19	7
2.2.2 Pneumonia Bakterial	7
2.2.3 Pneumonia Viral	7
2.3 Citra CXR	7
2.3.1 Citra Digital	7
2.3.2 CXR	8
2.4 <i>Preprocessing</i> dan <i>Augmentasi Data</i>	9
2.5 <i>Generative Adversarial Network (GAN)</i>	10
2.6 <i>Wasserstein Generative Adversarial Network (WGAN)</i>	12
2.7 WGAN-GP	14
2.7.1 Generator	15
2.7.2 Critic	16
2.7.3 Proses Pelatihan WGAN-GP	17

2.7.4	Evaluasi Model WGAN-GP.....	18
2.8	CNN	19
2.8.1	<i>Convolutional Layer</i>	20
2.8.2	<i>Pooling Layer</i>	21
2.8.3	Fungsi Aktivasi	22
2.8.4	<i>Fully Connected Layer</i>	23
2.8.5	Fungsi <i>Loss</i>	24
2.8.6	Fungsi Optimasi	24
2.8.7	ResNet50.....	25
2.8.8	Evaluasi Model Klasifikasi	27
2.9	Hyperparameter Penelitian.....	27
BAB 3	METODE PENELITIAN	29
3.1	Sumber Data.....	29
3.2	Variabel Penelitian.....	29
3.3	Struktur Data	29
3.4	Langkah Analisis.....	30
3.5	Diagram Alir Penelitian	31
3.6	Jadwal Penelitian.....	33
	DAFTAR PUSTAKA.....	35

DAFTAR GAMBAR

Gambar 2. 1 Koordinat Spasial Citra Digital.....	8
Gambar 2. 2 Karakteristik citra CXR pada berbagai kondisi infeksi paru	9
Gambar 2. 3 Citra Rotasi	9
Gambar 2. 4 Citra Flip Horizontal	10
Gambar 2. 5 Citra Translasi	10
Gambar 2. 6 Citra Perubahan Skala	10
Gambar 2. 7 Arsitektur GAN.....	11
Gambar 2. 8 Arsitektur WGAN-GP.....	14
Gambar 2. 9 Arsitektur CNN	20
Gambar 2. 10 Ilustrasi Proses Konvolusi.....	20
Gambar 2. 11 Ilustrasi Proses Pooling pada CNN	21
Gambar 2. 12 Ilustrasi Proses flattening	23
Gambar 2. 13 Arsitektur ResNet-50	26
Gambar 3. 1 Diagram Alir Penelitian	32

(Halaman ini sengaja dikosongkan)

DAFTAR TABEL

Tabel 2. 1 Penelitian Terdahulu	5
Tabel 3. 1 Jumlah Gambar Menurut Kondisi Paru-Paru	29
Tabel 3. 2 Variabel Penelitian	29
Tabel 3. 3 Struktur Data dalam Proses Klasifikasi	29
Tabel 3. 4 Jadwal Penelitian	33

(Halaman ini sengaja dikosongkan)

DAFTAR NOTASI

I	:	Jumlah baris citra (tinggi citra)
J	:	Jumlah kolom citra (lebar citra)
i	:	Indeks koordinat vertikal (baris) citra
j	:	Indeks koordinat horizontal (kolom) citra
$X_{(i,j)}$	:	Nilai intensitas piksel pada koordinat (i, j)
G	:	Generator
D	:	Discriminator
$V(D, G)$	:	Fungsi nilai (<i>value function</i>) GAN
$x \sim p_r(x)$	:	Sampel data asli yang diambil dari distribusi data asli
$\tilde{x} \sim p_g(x)$	:	Sampel data sintetis hasil generator
$p_r(x)$	:	Distribusi data asli
$p_g(x)$	:	Distribusi data sintetis
$D(x)$	:	Probabilitas bahwa sampel x diklasifikasikan sebagai data asli
$D(\tilde{x})$	:	Probabilitas bahwa data sintetis diklasifikasikan sebagai data asli
$\mathbb{E}[\cdot]$	:	Nilai harapan terhadap distribusi
$D_G^*(x)$	:	Fungsi discriminator optimal untuk generator G
$C(G)$	:	Nilai fungsi objektif GAN untuk generator G
$JSD(p_r p_g)$	:	JSD antara distribusi data asli dan data sintetis
$W(p_r, p_g)$	:	<i>Wasserstein-1 distance</i> antara distribusi data asli data sintetis
γ	:	Distribusi gabungan dari pasangan sampel data asli dan data sintetis
$\Pi(p_r, p_g)$	:	Himpunan seluruh distribusi gabungan
$(x, \tilde{x}) \sim \gamma$	:	Pasangan sampel data asli dan data sintetis
$\ x - \tilde{x}\ $	:	Jarak Euclidean antara dua sampel
f	:	Fungsi bernilai real (<i>real-valued function</i>)
$\ f\ _L \leq 1$	:	Syarat bahwa fungsi f bersifat 1-Lipschitz
$f_w(\cdot)$	:	Critic dengan parameter w
F_L	:	Himpunan fungsi critic yang memenuhi syarat 1-Lipschitz
h	:	Representasi fitur dalam bentuk tensor
z	:	Vektor laten
$p(z)$	:	Distribusi normal standar untuk vektor laten
W	:	Matriks bobot
b	:	Vektor bias
$U(\cdot)$	:	Operasi <i>upsampling</i>
K	:	Kernel konvolusi
$*$	:	Operasi konvolusi
$\sigma(\cdot)$	:	Fungsi aktivasi nonlinier
$\tilde{x}$	:	Citra sintetis yang dihasilkan oleh generator
$D(\cdot)$	:	Operasi <i>downsampling</i>
M	:	Jumlah sampel dalam satu <i>mini-batch</i>
λ	:	Koefisien pinalti gradien
$\hat{x}$	:	Sampel interpolasi
L_C	:	Fungsi <i>loss</i> critic
ϵ	:	Bilangan acak yang diambil dari distribusi uniform
L_G	:	Fungsi <i>loss</i> generator
μ_r	:	Vektor rata-rata fitur citra asli

μ_g	: Vektor rata-rata fitur citra sintetis
Σ_r	: Matriks kovarians fitur citra asli
Σ_g	: Matriks kovarians fitur citra sintetis
$Tr(\cdot)$	: Operator <i>trace</i> matriks
x, y	: Pasangan citra yang dibandingkan
μ	: Nilai rata-rata intensitas citra
σ	: Varians intensitas citra
σ_{xy}	: Kovarians antara citra x dan y
C_1, C_2	: Konstanta stabilisasi untuk menghindari pembagian dengan nol
$F_{(i,j)}$	: Nilai <i>feature map</i> hasil konvolusi pada posisi (i, j)
U	: Tinggi kernel konvolusi
V	: Lebar kernel konvolusi
$P_{(i,j)}$	: Nilai <i>feature map</i> hasil pooling pada posisi (i, j) .
p, q	: Indeks posisi dalam jendela pooling
k	: Ukuran jendela pooling
e	: Bilangan euler
α	: Konstanta kecil bernilai positif
z_c	: Nilai logit untuk kelas ke- c
c	: Kelas yang diprediksi
C	: Jumlah kelas yang diprediksi
s	: Indeks pembantu untuk menjumlahkan nilai seluruh kelas agar hasilnya menjadi probabilitas
n	: Indeks urutan citra CXR dalam dataset
N	: Jumlah citra CXR dalam dataset
y_c	: Label sebenarnya untuk kelas ke- c
p_c	: Probabilitas prediksi model untuk kelas ke- c
L	: Fungsi <i>loss</i> CNN
w_t	: Parameter model pada iterasi ke- t
m_t	: Estimasi momen pertama (rata-rata gradien).
v_t	: Estimasi momen kedua (rata-rata kuadrat gradien).
β_1, β_2	: Koefisien momentum untuk momen pertama dan kedua
η	: <i>Learning rate</i>
$\nabla L(w_t)$	: Gradien fungsi <i>loss</i> terhadap parameter
n_{critic}	: Jumlah iterasi pelatihan jaringan <i>critic</i> per satu kali iterasi generator
$X_{n,i,j}$	: Nilai intensitas piksel pada citra ke- n posisi (i, j)
Y_n	: Label kondisi klinis (target) untuk citra ke- n

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Penyakit infeksi paru merupakan masalah kesehatan global yang serius karena memengaruhi fungsi sistem respirasi dan berisiko menyebabkan kematian, khususnya pada kasus pneumonia dan *Coronavirus Disease 2019* (COVID-19). Secara global pada tahun 2021, COVID-19 dan pneumonia (yang termasuk dalam kategori *lower respiratory infections*) tercatat sebagai bagian dari lima besar penyebab kematian tertinggi di dunia (World Health Organization, 2024). Sejak terjadinya pandemi COVID-19 jumlah kasus pneumonia akibat infeksi *SARS-CoV-2* mengalami peningkatan yang signifikan (Cohen et al., 2022). Sekitar 15–20% penderita COVID-19 mengalami pneumonia dengan tingkat keparahan tinggi, dan tanpa penanganan yang memadai sekitar 10% dari pasien tersebut dapat berujung pada kematian (Huang et al., 2020). Berdasarkan fakta tersebut, deteksi dini penyakit infeksi paru, khususnya pneumonia dan COVID-19, menjadi hal penting untuk mencegah terjadinya komplikasi lebih lanjut serta menekan angka kematian (Singh et al., 2024).

Chest X-Ray (CXR) merupakan salah satu alat diagnostik yang berguna untuk menilai berbagai penyakit infeksi paru, termasuk pneumonia dan COVID-19. Namun, proses interpretasi secara manual akan membutuhkan waktu yang relatif lama dan bergantung pada keahlian tenaga medis, sehingga menyebabkan keterlambatan dalam diagnosis dan pemberian penanganan yang tepat (Radha, 2025). Oleh karena itu, interpretasi CXR dapat dimaksimalkan menggunakan pendekatan *deep learning* khususnya *Convolutional Neural Network* (CNN) yang mampu melakukan ekstraksi fitur otomatis langsung dari citra medis. CNN mampu mengekstraksi fitur secara otomatis dari citra medis dengan mempelajari pola kompleks seperti struktur anatomi paru-paru dan ciri radiologis penyakit. Implementasi CNN memungkinkan analisis CXR dilakukan secara cepat dan akurat tanpa bergantung pada variabilitas pengamat manusia maupun keterbatasan alat diagnostik molekuler.

Berbagai penelitian terdahulu telah berupaya mengoptimalkan klasifikasi penyakit infeksi paru menggunakan CXR tetapi masih terdapat celah penelitian yang perlu ditangani. Salah satu penelitian menunjukkan bahwa klasifikasi pneumonia berbasis CNN dengan pendekatan *transfer learning* menggunakan ResNet-50 mampu mencapai tingkat akurasi sebesar 0,91. Namun, penelitian tersebut masih terbatas pada klasifikasi biner, yaitu kelas normal dan pneumonia (Maquen-Niño et al., 2024). Penelitian selanjutnya mengembangkan skema klasifikasi menjadi multikelas yang mencakup normal, pneumonia, dan COVID-19 dengan memanfaatkan Xception, serta memperoleh akurasi sebesar 0,87. Meskipun demikian, pendekatan tersebut masih memiliki keterbatasan karena pneumonia belum dibedakan secara lebih spesifik berdasarkan etiologinya, seperti pneumonia viral dan pneumonia bakterial (Baker et al., 2024).

Penelitian selanjutnya memanfaatkan ResNet-50 untuk melakukan klasifikasi citra CXR ke dalam empat kelas, yaitu normal, pneumonia bakterial, pneumonia viral, dan COVID-19, dengan akurasi sebesar 0,83. Pendekatan ini menunjukkan kemampuan yang cukup baik dalam skenario klasifikasi multikelas. Namun demikian, performa model dalam membedakan antara pneumonia bakterial dan pneumonia viral masih tergolong rendah, yang tercermin dari nilai *F1-score* terendah pada kelas pneumonia viral sebesar 0,57 (Office et al., 2024). Temuan tersebut diperkuat oleh penelitian berikutnya yang menerapkan model ResNet-50 untuk klasifikasi tiga kelas, yaitu normal, pneumonia bakterial, dan pneumonia viral, dengan akurasi keseluruhan mencapai 0,83. Meskipun akurasi model tergolong baik, hasil klasifikasi

menunjukkan adanya pengaruh ketidakseimbangan data antarkelas, pneumonia bakterial dan pneumonia viral, yang berdampak pada penurunan performa model (Lestari, 2025).

Pneumonia bakterial umumnya ditandai oleh infiltrat alveolar, khususnya pola lobar pada citra CXR, sedangkan pneumonia viral lebih sering memperlihatkan infiltrat interstisial yang bersifat tidak spesifik dan dapat tumpang tindih dengan pneumonia bakterial (Virkki et al., 2002). Namun, kemiripan karakteristik visual antara kedua pola tersebut sering kali menyulitkan CNN untuk membedakan jenis pneumonia. Tantangan ini semakin diperbesar oleh adanya ketidakseimbangan jumlah data antarkelas, khususnya antara pneumonia viral dan pneumonia bakterial, yang pada akhirnya berdampak pada menurunnya kemampuan model dalam mengenali dan mengklasifikasikan tipe pneumonia secara akurat. Rangkaian penelitian tersebut menunjukkan bahwa ketidakseimbangan data merupakan permasalahan serius dalam klasifikasi penyakit infeksi paru berbasis citra CXR, terutama dalam membedakan jenis pneumonia berdasarkan etiologinya.

Permasalahan ketidakseimbangan data juga ditemukan pada bidang klasifikasi citra medis lainnya, salah satunya pada penyakit Alzheimer. Penelitian sebelumnya menunjukkan bahwa pendekatan *Wasserstein Generative Adversarial Network* dengan *Gradient Penalty* (WGAN-GP) yang dikombinasikan dengan AlexNet mampu mengatasi ketidakseimbangan kelas dan meningkatkan performa klasifikasi hingga mencapai akurasi sebesar 0,95 pada pengelompokan empat stadium penyakit Alzheimer (Alamudin et al., 2025). Hasil tersebut menunjukkan bahwa pendekatan generatif berbasis WGAN-GP efektif dalam memperbaiki distribusi data latih pada skenario klasifikasi citra medis. Namun, penelitian tersebut masih terbatas pada penggunaan dataset citra *Magnetic Resonance Imaging* (MRI), sehingga efektivitas WGAN-GP pada citra CXR untuk klasifikasi penyakit infeksi paru masih belum banyak dikaji.

Berdasarkan permasalahan tersebut, pendekatan berbasis generatif, khususnya WGAN-GP, memiliki potensi besar sebagai solusi untuk mengatasi ketidakseimbangan data pada klasifikasi citra medis. Dalam penelitian ini, WGAN-GP dimanfaatkan untuk menghasilkan citra sintetis yang representatif pada kelas minoritas guna memperbaiki distribusi data latih. Selanjutnya, proses klasifikasi dilakukan menggunakan arsitektur CNN berbasis *transfer learning* ResNet-50, yang telah terbukti efektif dalam mengekstraksi fitur kompleks dari citra CXR. Integrasi WGAN-GP dengan ResNet50 diharapkan mampu meningkatkan akurasi klasifikasi penyakit infeksi paru, khususnya dalam membedakan pneumonia bakterial dan pneumonia viral, serta mendukung proses diagnosis yang lebih cepat dan akurat oleh tenaga medis.

1.2 Rumusan Masalah

Permasalahan utama dalam penelitian ini adalah ketidakseimbangan distribusi data antarkelas pada citra CXR yang berpotensi menurunkan kinerja model klasifikasi berbasis CNN dengan arsitektur *transfer learning* ResNet-50, khususnya dalam membedakan pneumonia bakterial dan pneumonia viral. Oleh karena itu, penelitian ini mengkaji penerapan WGAN-GP sebagai pendekatan generatif untuk mengatasi ketidakseimbangan data serta menganalisis pengaruhnya terhadap kinerja klasifikasi citra CXR ke dalam empat kelas, yaitu normal, COVID-19, pneumonia bakterial, dan pneumonia viral.

1.3 Tujuan

Berdasarkan rumusan masalah penelitian ini, tujuan dari penelitian ini adalah sebagai berikut:

1. Mengetahui kinerja model klasifikasi citra CXR penyakit infeksi paru menggunakan arsitektur CNN berbasis *transfer learning* ResNet50 dalam mengklasifikasikan citra ke

dalam empat kelas, yaitu normal, COVID-19, pneumonia bakterial, dan pneumonia viral, pada kondisi ketidakseimbangan data antarkelas.

2. Menerapkan WGAN-GP sebagai pendekatan generatif untuk mengatasi ketidakseimbangan distribusi data pada klasifikasi citra CXR.
3. Menganalisis pengaruh penerapan WGAN-GP terhadap peningkatan kinerja model klasifikasi berbasis ResNet50, khususnya dalam membedakan pneumonia bakterial dan pneumonia viral.

1.4 Manfaat

Manfaat yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi ilmiah dalam pengembangan metode klasifikasi penyakit infeksi paru berbasis citra CXR melalui integrasi WGAN-GP dan model CNN berbasis *transfer learning* ResNet-50 untuk mengatasi permasalahan ketidakseimbangan data.
2. Menjadi referensi bagi penelitian selanjutnya terkait penerapan teknik augmentasi data berbasis model generatif dalam menangani ketidakseimbangan data, serta pengembangan model CNN berbasis *transfer learning* untuk klasifikasi penyakit infeksi paru, sehingga dapat mendukung deteksi dini dan pengambilan keputusan klinis yang lebih cepat dan akurat.

1.5 Batasan Masalah

Penelitian ini difokuskan pada klasifikasi multikelas penyakit infeksi paru berdasarkan citra CXR menggunakan metode CNN berbasis *transfer learning* ResNet50 yang diintegrasikan dengan WGAN-GP untuk augmentasi data. Klasifikasi dilakukan terhadap empat kelas, yaitu normal, COVID-19, pneumonia bakterial, dan pneumonia viral. Dataset yang digunakan dalam penelitian ini bersumber dari *Mendeley Data* dengan total 9.208 citra CXR. Penelitian ini dibatasi pada pengembangan dan evaluasi model WGAN-GP dalam menghasilkan citra sintesis menggunakan *Frechet Inception Distance* (FID) dan *Structural Similarity Index Measure* (SSIM). Selanjutnya, evaluasi kinerja model klasifikasi dilakukan menggunakan metrik *accuracy*, *precision*, *sensitivity*, dan *F1-score* tanpa melibatkan validasi klinis atau penerapan langsung di fasilitas kesehatan.

(Halaman ini sengaja dikosongkan)

BAB 2

TINJAUAN PUSTAKA

2.1 Hasil Penelitian Terdahulu

Tabel 2.1 merangkum penelitian terdahulu terkait klasifikasi citra medis, termasuk penyakit infeksi paru dan penelitian lain yang menerapkan WGAN-GP untuk menangani ketidakseimbangan data, sebagai dasar pengembangan penelitian ini.

Tabel 2. 1 Penelitian Terdahulu

No	Penulis	Analisis	Hasil Analisis	Kelebihan/Kekurangan/Gap Penelitian
1.	(Maquen-Niño et al., 2024)	Deteksi pneumonia pada citra CRX menggunakan <i>transfer learning</i> . Metode: DenseNet, VGG19, dan ResNet-50.	Model ResNet-50 menunjukkan performa terbaik dengan tingkat akurasi sebesar 0,91 pada skenario klasifikasi biner.	Kelebihan: Model mampu mencapai tingkat akurasi yang tinggi dan dataset yang digunakan seimbang. Kekurangan: Cakupan klasifikasi masih terbatas pada kategori biner (dua kelas), sehingga belum mampu mengidentifikasi variasi kondisi klinis yang lebih kompleks. Gap Penelitian: Penelitian ini belum mempertimbangkan klasifikasi multikelas. Oleh karena itu, penelitian ini mengusulkan integrasi WGAN-GP dan ResNet-50 untuk klasifikasi penyakit infeksi paru berbasis citra CXR ke dalam empat kelas.
2.	(Baker et al., 2024)	Deteksi COVID-19 menggunakan CNN dan <i>transfer learning</i> . Metode: DenseNet-201, VGG-16, ResNet-50, Inception-V3, Inception-ResNet-V2, Xception.	Model Xception menjadi model terbaik dengan akurasi sebesar 0,98 dalam melakukan klasifikasi biner dan 0,87 dalam melakukan klasifikasi multikelas.	Kelebihan: Model mampu mencapai tingkat akurasi yang tinggi dan dataset yang digunakan seimbang. Kekurangan: Klasifikasi multi-kelas masih terdiri dari tiga kelas saja yaitu normal, COVID-19, dan pneumonia. Gap Penelitian: Penelitian ini belum mengkaji klasifikasi penyakit infeksi paru secara lebih spesifik pada skenario empat kelas. Oleh karena itu, penelitian ini mengusulkan integrasi WGAN-GP dan ResNet-50 untuk klasifikasi penyakit infeksi paru berbasis citra CXR ke dalam empat kelas.
3.	(Office et al., 2024)	Klasifikasi Pneumonia menggunakan Metode CNN. Metode: ResNet-50.	Model ResNet-50 berhasil mencapai akurasi sebesar 0,83 dalam melakukan klasifikasi multikelas.	Kelebihan: Model menunjukkan performa klasifikasi yang cukup baik secara keseluruhan. Kekurangan: Rendahnya presisi pada kelas pneumonia bakterial dan pneumonia viral menunjukkan bahwa ketidakseimbangan data antarkelas masih memengaruhi kinerja klasifikasi model. Gap Penelitian: Penelitian ini belum menerapkan teknik penanganan ketidakseimbangan data. Oleh karena itu, penelitian ini mengusulkan penerapan WGAN-GP untuk memperbaiki distribusi data latih dan meningkatkan kinerja klasifikasi.

Tabel 2. 1 (lanjutan)

No	Penulis	Analisis	Hasil Analisis	Kelebihan/Kekurangan/Gap Penelitian
4.	(Lestari, 2025)	Klasifikasi pneumonia bakterial dan viral menggunakan CXR. Metode: Xception, Inception-V3, ResNet-50-V2, DenseNet-201.	Model ResNet-50 memberikan performa terbaik dengan tingkat akurasi sebesar 0,83 pada skenario klasifikasi multikelas..	Kelebihan: Model mampu mencapai tingkat akurasi yang tinggi. Kekurangan: Akurasi keseluruhan model tergolong baik, tetapi performa klasifikasi masih menunjukkan pengaruh ketidakseimbangan data antarkelas yang masih terdiri dari tiga kelas saja yaitu normal, pneumonia bakterial, dan pneumonia viral. Gap Penelitian: Penelitian ini belum mengakomodasi klasifikasi empat kelas dan belum menerapkan teknik penanganan ketidakseimbangan data. Oleh karena itu, penelitian ini mengusulkan integrasi WGAN-GP untuk mengatasi ketidakseimbangan data dalam klasifikasi multikelas citra CXR.
5.	(Alamudin et al., 2025)	Penerapan pendekatan generatif untuk mengatasi data tidak seimbang pada klasifikasi penyakit Alzheimer. Metode: WGAN-GP dan CNN.	Integrasi AlexNet dan WGAN-GP mampu meningkatkan performa klasifikasi dengan akurasi mencapai 0,95 dalam pengelompokan empat stadium penyakit Alzheimer.	Kelebihan: Pendekatan WGAN-GP terbukti efektif dalam memperbaiki distribusi data latih dan meningkatkan akurasi klasifikasi pada kondisi ketidakseimbangan data. Kekurangan: Penelitian ini masih terbatas pada dataset citra MRI penyakit Alzheimer. Gap Penelitian: Belum terdapat kajian yang secara khusus membahas penerapan WGAN-GP pada citra CXR untuk klasifikasi penyakit infeksi paru dengan skema empat kelas, yaitu normal, COVID-19, pneumonia bakterial, dan pneumonia viral. Oleh karena itu, penelitian ini menerapkan WGAN-GP pada dataset citra CXR paru-paru untuk menangani ketidakseimbangan distribusi data antarkelas, khususnya pada kelas minoritas guna meningkatkan kinerja model klasifikasi berbasis CNN.

2.2 Penyakit Infeksi Paru

Penyakit infeksi paru, khususnya pneumonia dan COVID-19, merupakan masalah kesehatan global yang serius dengan tingkat morbiditas dan mortalitas yang tinggi (Troeger et al., 2018). Infeksi ini menyerang parenkim paru dan alveoli sehingga memicu proses inflamasi yang dapat berkembang menjadi komplikasi berat apabila tidak ditangani secara tepat. Keterlambatan diagnosis dan intervensi medis diketahui berkontribusi signifikan terhadap peningkatan risiko kematian akibat penyakit infeksi paru. Oleh karena itu, deteksi dini menjadi sangat penting dalam mengidentifikasi perubahan radiologis pada paru-paru serta mendukung proses diagnosis dan pengambilan keputusan klinis secara cepat.

2.2.1 COVID-19

Infeksi COVID-19 akibat virus *SARS-CoV-2* dapat berkembang menjadi pneumonia berat pada sekitar 15–20% kasus, dengan angka kematian mencapai sekitar 10% apabila tidak ditangani secara tepat (Huang et al., 2020). Fakta medis menunjukkan bahwa infeksi ini sering menyebabkan *silent hypoxemia*, di mana pasien tampak stabil secara fisik namun kadar oksigen dalam darahnya telah turun ke level yang mengancam jiwa (Lukito, 2020). Jika kondisi ini tidak dikenali dan ditangani sejak awal, infeksi dapat berkembang menjadi *Acute Respiratory Distress Syndrome* (ARDS) dengan kerusakan paru (*diffuse alveolar damage*) (Batah & Fabro, 2021). Mengingat sifat penyakit ini yang sangat menular, deteksi dini menjadi semakin krusial, tidak hanya untuk menyelamatkan pasien tetapi juga untuk memutus rantai penyebaran di masyarakat.

2.2.2 Pneumonia Bakterial

Pneumonia bakterial merupakan infeksi paru yang paling sering disebabkan oleh *Streptococcus pneumoniae* dan *Haemophilus influenzae* tipe b pada anak. Infeksi ini menyebabkan alveoli terisi nanah dan cairan akibat respons inflamasi terhadap bakteri (World Health Organization, 2022). Studi menunjukkan bahwa sekitar 72% kasus pneumonia bakterial memperlihatkan infiltrat alveolar, dengan pola lobar yang lebih sering ditemukan dibandingkan pneumonia viral (Virkki et al., 2002). Secara klinis, pneumonia bakterial umumnya ditandai dengan demam tinggi, napas cepat, dan retraksi dinding dada. Penanganan utama pneumonia bakterial adalah pemberian antibiotik yang tepat dan cepat. Oleh karena itu, deteksi dini sangat penting untuk memungkinkan terapi segera, mencegah komplikasi berat, dan menurunkan angka kematian.


2.2.3 Pneumonia Viral

Pneumonia viral merupakan infeksi paru yang paling sering disebabkan oleh virus respiratori, terutama *respiratory syncytial virus* (RSV), influenza, dan adenovirus pada anak. Infeksi ini menimbulkan peradangan pada jaringan interstisial paru tanpa pembentukan nanah seperti pada pneumonia bakterial, sehingga alveoli umumnya terisi cairan inflamasi non-purulen (World Health Organization, 2022). Studi menunjukkan bahwa pneumonia viral lebih sering berkaitan dengan infiltrat interstisial, meskipun temuan ini tidak spesifik dan dapat tumpang tindih dengan pneumonia bakterial (Virkki et al., 2002). Secara klinis, pneumonia viral umumnya ditandai dengan batuk, demam ringan hingga sedang, dan *wheezing* yang lebih sering ditemukan dibandingkan pneumonia bakterial. Oleh karena itu, deteksi dini tetap penting untuk memastikan pemantauan yang tepat, mencegah perburukan kondisi, serta menghindari penggunaan antibiotik yang tidak perlu.

2.3 Citra CXR

2.3.1 Citra Digital

Citra digital merupakan gambar yang direpresentasikan sebagai fungsi dua dimensi $X_{(i,j)}$. Variabel (i,j) pada fungsi tersebut menunjukkan posisi suatu titik koordinat spasial, sedangkan nilai X menyatakan tingkat kecerahan atau intensitas pada titik tersebut. Citra ini disusun oleh elemen-elemen kecil yang terbatas yang disebut sebagai piksel (*picture element*). Setiap piksel memiliki posisi dan nilai tertentu yang disajikan dalam bentuk matriks sehingga dapat diproses secara digital oleh komputer. Sistem koordinat pada citra digital memiliki karakteristik khusus dengan titik asal atau *origin* (0,0) yang terletak pada sudut kiri atas. (Kaur, 2025).



Gambar 2. 1 Koordinat Spasial Citra Digital

Representasi koordinat pada Gambar 2.1 memungkinkan sebuah citra digital berukuran $I \times J$ disajikan secara matematis dalam bentuk matriks yang lebih kompak. Setiap elemen di dalam matriks menunjukkan nilai intensitas cahaya pada koordinat (i, j) tertentu. Bentuk representasi matriks citra digital ini dapat dilihat pada Persamaan 2.1

$$X_{(i,j)} = \begin{bmatrix} X_{(0,0)} & X_{(0,1)} & \dots & X_{(0,J-1)} \\ X_{(1,0)} & X_{(1,1)} & \dots & X_{(1,J-1)} \\ \vdots & \vdots & & \vdots \\ X_{(I-1,0)} & X_{(I-1,1)} & \dots & X_{(I-1,J-1)} \end{bmatrix} \quad (2.1)$$

Keterangan:

I : Jumlah baris citra (tinggi citra).

J : Jumlah kolom citra (lebar citra).

i : Indeks koordinat vertikal (baris) citra, dengan nilai $i = 0, 1, \dots, I - 1$.

j : Indeks koordinat horizontal (kolom) citra, dengan nilai $j = 0, 1, \dots, J - 1$.


$X_{(i,j)}$: Nilai intensitas piksel pada koordinat (i, j) .

Citra digital dikategorikan menjadi tiga jenis utama berdasarkan nilai intensitasnya. Pertama adalah citra biner yang hanya memiliki dua nilai intensitas, yaitu hitam dan putih, dengan ukuran representasi 1 bit per piksel. Jenis kedua adalah citra *grayscale* yang menampilkan variasi tingkat abu-abu dari gelap hingga terang dengan 256 tingkat intensitas pada rentang nilai 0–255 dan ukuran 8 bit per piksel. Jenis ketiga adalah citra berwarna atau RGB yang dibentuk dari kombinasi warna merah (*Red*), hijau (*Green*), dan biru (*Blue*), di mana setiap komponen warna memiliki rentang nilai 0–255 sehingga membutuhkan total 24 bit per piksel untuk merepresentasikan berbagai variasi warna. Gambar-gambar tersebut kemudian dapat dianalisis untuk memperoleh informasi penting melalui berbagai teknik pengolahan citra. Saat ini, penerapan teknologi tersebut telah meluas di berbagai bidang, terutama pada sektor medis untuk menganalisis hasil pemindaian seperti MRI dan CXR.

2.3.2 CXR

CXR memiliki peran penting dalam memahami mekanisme patofisiologi serta mendukung proses identifikasi penyakit infeksi paru yang berpotensi mengancam jiwa. Berbagai penelitian menunjukkan bahwa pengenalan pola infiltrat secara visual pada CXR dapat membantu

membedakan karakteristik kerusakan paru secara cepat. Pada kondisi normal, paru-paru tampak radiolusen tanpa adanya infiltrat. Pada pasien COVID-19, citra CXR umumnya memperlihatkan pola *ground-glass opacity* (GGO) yang terdistribusi bilateral dan perifer (Sadiq et al., 2021). Pneumonia bakterial umumnya ditandai oleh infiltrat alveolar, khususnya pola lobar pada citra CXR, sedangkan pneumonia viral lebih sering memperlihatkan infiltrat interstisial yang bersifat tidak spesifik dan dapat tumpang tindih dengan pneumonia bakterial (Virkki et al., 2002). Kemampuan mengidentifikasi perbedaan karakteristik visual pada masing-masing kelas penyakit melalui citra CXR berperan penting dalam mencegah keterlambatan diagnosis dan penanganan klinis. Perbedaan karakteristik tersebut dapat diamati secara visual pada citra CXR sebagaimana ditunjukkan pada Gambar 2.2.




Gambar 2. 2 Karakteristik citra CXR pada berbagai kondisi infeksi paru: (a) Normal, (b) COVID-19, (c) Pneumonia Bakterial, dan (d) Pneumonia Viral. (Sumber: Sait et al., 2021)

2.4 Preprocessing dan Augmentasi Data


Tahap *preprocessing* memiliki peran penting dalam penelitian ini untuk mempersiapkan data sebelum masuk ke tahap klasifikasi. Citra CXR terlebih dahulu diproses melalui tahap penyamaan ukuran (*resizing*) agar seluruh data masukan memiliki dimensi yang seragam, sehingga memastikan kesesuaian citra dengan arsitektur model yang digunakan. Selanjutnya, citra diproses menggunakan *ImageDataGenerator* yang mencakup normalisasi nilai piksel serta penerapan berbagai teknik augmentasi pada data latih sebagai berikut:

- a. **Rotasi (*Rotation*)**: Melakukan perputaran citra pada derajat tertentu untuk meningkatkan variasi sudut pandang model terhadap fitur anatomis. Contoh hasil rotasi citra dapat dilihat pada Gambar 2.3.




Gambar 2. 3 Citra Rotasi

- b. **Pembalikan Horizontal (*Horizontal Flipping*)**: Membalik citra secara horizontal untuk menghasilkan refleksi data tanpa mengubah karakteristik fitur medis secara signifikan. Ilustrasi pembalikan horizontal ditunjukkan pada Gambar 2.4.




Gambar 2. 4 Citra Flip Horizontal

- c. **Translasi (*Translation*)**: Menggeser citra secara horizontal atau vertikal agar model mampu mengenali objek meskipun posisinya tidak tepat berada di tengah. Hasil pergeseran ini ditampilkan pada Gambar 2.5.



Gambar 2. 5 Citra Translasi

- d. **Perubahan Skala (*Scaling*)**: Memperbesar atau memperkecil citra untuk membuat model lebih adaptif terhadap variasi ukuran objek pada data asli. Contoh perubahan skala citra dapat dilihat pada Gambar 2.6.




Gambar 2. 6 Citra Perubahan Skala

Selain augmentasi konvensional tersebut, penelitian ini juga menggunakan WGAN-GP untuk menghasilkan citra CXR sintetis. Pendekatan ini digunakan untuk menambah data latih yang karakteristiknya mendekati data asli, khususnya pada kelas minoritas, sehingga diharapkan mampu meningkatkan kinerja model klasifikasi (Shorten & Khoshgoftaar, 2019).

2.5 *Generative Adversarial Network (GAN)*

GAN diperkenalkan sebagai model pembelajaran generatif yang terdiri dari dua jaringan saraf, yaitu generator G dan discriminator D , yang dilatih secara adversarial. Generator

berfungsi untuk mengubah vektor noise acak z yang diambil dari distribusi normal standar $p(z)$ menjadi data sintetis $\tilde{x}$, sehingga distribusi data yang dihasilkan generator dinotasikan sebagai $p_g(x)$. Sementara itu, discriminator menerima masukan berupa data asli x yang diambil dari distribusi data nyata $p_r(x)$ serta data sintetis $\tilde{x}$ yang berasal dari distribusi $p_g(x)$, kemudian memberikan estimasi probabilitas bahwa data yang diberikan merupakan data asli (Goodfellow et al., 2014). Arsitektur GAN secara umum ditunjukkan pada Gambar 2.7.



Gambar 2. 7 Arsitektur GAN

Proses pelatihan GAN berlangsung secara iteratif melalui mekanisme kompetisi antara generator dan discriminator. Pada setiap iterasi, generator menghasilkan sampel data sintetis dari ruang laten berdasarkan vektor noise z , kemudian discriminator mengevaluasi sampel tersebut bersama dengan sampel data asli. Discriminator berusaha membedakan kedua jenis data, sedangkan generator berusaha menghasilkan data sintetis yang semakin menyerupai data asli sehingga sulit dibedakan oleh discriminator. Secara matematis, proses pelatihan GAN diformulasikan sebagai masalah optimasi *minimax*, di mana generator dan discriminator saling berkompetisi sebagaimana dirumuskan pada Persamaan (2.2).

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_r(x)} [\log D(x)] + \mathbb{E}_{\tilde{x} \sim p_g(x)} [\log (1 - D(\tilde{x}))] \quad (2.2)$$

Keterangan:

G : Generator.

D : Discriminator.

$V(D, G)$: Fungsi nilai (*value function*) GAN.

$x \sim p_r(x)$: Sampel data asli yang diambil dari distribusi data asli.

$\tilde{x} \sim p_g(x)$: Sampel data sintetis hasil generator.

$p_r(x)$: Distribusi data asli.

$p_g(x)$: Distribusi data sintetis.

$D(x)$: Probabilitas bahwa sampel x diklasifikasikan sebagai data asli.

$D(\tilde{x})$: Probabilitas bahwa data sintetis diklasifikasikan sebagai data asli.

$\mathbb{E}[\cdot]$: Nilai harapan terhadap distribusi terkait.

Melalui mekanisme *backpropagation*, nilai *loss* yang diperoleh dari fungsi objektif digunakan untuk memperbarui parameter generator dan discriminator secara bergantian. Discriminator dilatih untuk meningkatkan kemampuannya dalam membedakan data asli dan data sintetis, sedangkan generator diperbarui untuk meminimalkan kemampuan discriminator

dalam mengenali data sintetis. Proses kompetitif ini berlangsung secara berulang hingga mencapai kondisi keseimbangan (*equilibrium*), di mana generator mampu menghasilkan data sintetis yang secara statistik konsisten dengan karakteristik distribusi data asli. Secara teoretis, apabila discriminator dilatih hingga mencapai kondisi optimal pada setiap iterasi, maka fungsi discriminator optimal dapat dinyatakan sebagaimana pada Persamaan (2.3).

$$D_G^*(x) = \frac{p_r(x)}{p_r(x) + p_g(x)} \quad (2.3)$$

Keterangan:

$D_G^*(x)$: Fungsi discriminator optimal untuk generator G .

x : Titik pada ruang data.

Apabila Persamaan (2.3) disubstitusikan ke dalam fungsi nilai GAN, maka diperoleh hubungan antara fungsi objektif GAN dan ukuran kesamaan distribusi probabilitas. Hubungan tersebut dinyatakan melalui *Jensen–Shannon Divergence* (JSD), sebagaimana dirumuskan pada Persamaan (2.4).

$$C(G) = -\log 4 + 2 \text{JSD}(p_r || p_g) \quad (2.4)$$

Keterangan:

$C(G)$: Nilai fungsi objektif GAN untuk generator G .

$\text{JSD}(p_r || p_g)$: JSD antara distribusi data asli dan data sintetis.

Pada Persamaan (2.3), nilai JSD dihitung terhadap distribusi p_r dan p_g secara keseluruhan, bukan terhadap nilai densitas pada titik tertentu. Persamaan ini menunjukkan bahwa fungsi objektif *minimax* GAN secara teoretis mendorong generator untuk meminimalkan perbedaan antara distribusi data sintetis dan distribusi data asli. Nilai minimum global sebesar $-\log 4$ dicapai ketika nilai JSD ($p_r || p_g$) = 0, yang mengindikasikan bahwa distribusi data sintetis telah identik dengan distribusi data asli ($p_g = p_r$).

Namun, dalam praktiknya, GAN klasik sering mengalami permasalahan *vanishing gradient*, terutama ketika discriminator menjadi terlalu akurat dalam membedakan data asli dan data sintetis. Pada kondisi tersebut, nilai *loss* mengalami saturasi sehingga gradien yang diteruskan ke generator menjadi kecil dan tidak lagi memberikan sinyal pembelajaran yang efektif. Selain itu, GAN juga rentan terhadap permasalahan *mode collapse*, yaitu kondisi ketika generator hanya mampu menghasilkan variasi data yang terbatas, serta menunjukkan ketidakstabilan selama proses pelatihan (G. Cohen & Giryas, 2023).

2.6 Wasserstein Generative Adversarial Network (WGAN)

GAN klasik memiliki beberapa keterbatasan, di antaranya permasalahan *mode collapse* dan ketidakstabilan proses pelatihan. Sebagai alternatif, (Arjovsky et al., 2017) mengusulkan WGAN, yang menggantikan JSD dengan *Wasserstein distance* atau *Earth Mover's Distance* (EMD) sebagai ukuran perbedaan antara distribusi data asli p_r dan distribusi data sintetis p_g . Berbeda dengan JSD, *Wasserstein distance* mengukur biaya minimum yang diperlukan untuk mentransformasikan satu distribusi probabilitas menjadi distribusi lainnya, sehingga

memberikan ukuran perbedaan distribusi yang lebih bermakna dan stabil selama proses pelatihan. Secara matematis, *Wasserstein-1 distance* didefinisikan sebagaimana ditunjukkan pada Persamaan (2.5).

$$W(p_r, p_g) = \inf_{\gamma \in \Pi(p_r, p_g)} \mathbb{E}_{(x, \tilde{x}) \sim \gamma} [\|x - \tilde{x}\|] \quad (2.5)$$

Keterangan:

$W(p_r, p_g)$: *Wasserstein-1 distance* antara distribusi data asli dan distribusi data sintetis.

γ : distribusi gabungan dari pasangan sampel data asli dan data sintetis.

$\Pi(p_r, p_g)$: Himpunan seluruh distribusi gabungan yang memiliki marginal p_r dan p_g .

$(x, \tilde{x}) \sim \gamma$: Pasangan sampel data asli dan data sintetis.

$\|x - \tilde{x}\|$: Jarak Euclidean antara dua sampel.

Formulasi pada Persamaan (2.5) memberikan interpretasi intuitif mengenai *Wasserstein distance* sebagai biaya minimum untuk memindahkan massa probabilitas dari distribusi data sintetis menuju distribusi data asli. Namun, formulasi ini sulit dihitung secara langsung karena melibatkan optimisasi atas seluruh distribusi gabungan γ . Oleh karena itu, berdasarkan teorema *Kantorovich–Rubinstein duality*, *Wasserstein distance* dapat dinyatakan dalam bentuk dual sebagaimana ditunjukkan pada Persamaan (2.6).

$$W(p_r, p_g) = \sup_{\|f\|_L \leq 1} \mathbb{E}_{x \sim p_r} [f(x)] - \mathbb{E}_{\tilde{x} \sim p_g} [f(\tilde{x})] \quad (2.6)$$

Keterangan:

f : Fungsi bernilai real (*real-valued function*).

$\|f\|_L \leq 1$: Syarat bahwa fungsi f bersifat 1-Lipschitz.

Syarat 1-Lipschitz memastikan bahwa perubahan keluaran fungsi f dibatasi oleh perubahan masukannya, sehingga perhitungan *Wasserstein distance* menjadi stabil. Secara matematis, syarat 1-Lipschitz dinyatakan sebagaimana pada Persamaan (2.7).

$$|f(x_1) - f(x_2)| \leq \|x_1 - x_2\| \quad (2.7)$$

Formulasi dual pada Persamaan (2.6) menjadi dasar fungsi objektif WGAN. Berbeda dengan GAN klasik yang menggunakan discriminator untuk menghasilkan probabilitas klasifikasi, WGAN menggunakan sebuah jaringan saraf yang disebut critic, yang direpresentasikan sebagai fungsi f_w . Critic bertugas memberikan skor bernilai real terhadap setiap sampel data untuk mengaproksimasi *Wasserstein distance* antara distribusi data asli dan data sintetis. Dengan demikian, proses pelatihan WGAN diformulasikan sebagai permasalahan optimisasi *min–max* antara generator dan critic, sebagaimana ditunjukkan pada Persamaan (2.8).

$$\min_G \max_{f_w \in F_L} \mathbb{E}_{x \sim p_r} [f_w(x)] - \mathbb{E}_{\tilde{x} \sim p_g} [f_w(\tilde{x})] \quad (2.8)$$

Keterangan:

$f_w(\cdot)$: Fungsi critic dengan parameter w .

F_L : Himpunan fungsi critic yang memenuhi syarat 1-Lipschitz.

Pada WGAN, proses pelatihan dilakukan secara bergantian antara critic dan generator. Critic dilatih untuk memaksimalkan selisih nilai ekspektasi antara data asli dan data sintetis


sebagai estimasi *Wasserstein distance*, sedangkan generator dilatih untuk meminimalkan nilai tersebut agar distribusi data sintetis yang dihasilkan semakin mendekati distribusi data asli. Berbeda dengan GAN klasik yang mengandalkan probabilitas klasifikasi benar atau salah, critic pada WGAN menghasilkan skor bernilai real yang merepresentasikan kualitas suatu sampel berdasarkan kedekatannya terhadap distribusi data asli.

Pendekatan ini memberikan keunggulan utama dibandingkan GAN klasik. Secara matematis, *Wasserstein distance* bersifat kontinu dan hampir selalu terdiferensialkan terhadap parameter generator, bahkan ketika distribusi data asli p_r dan distribusi data sintetis p_g tidak saling tumpang tindih. Sifat ini memastikan bahwa gradien yang diteruskan ke generator tetap informatif sepanjang proses pelatihan, sehingga mengurangi permasalahan *vanishing gradient* dan meningkatkan stabilitas pelatihan model (Arjovsky et al., 2017).

Meskipun WGAN mampu 1-Lipschitz mengatasi permasalahan pada GAN, penerapan kendala pada fungsi critic masih menjadi tantangan dalam praktik. Pada WGAN awal, kendala ini ditegakkan melalui teknik *weight clipping*, yaitu pembatasan nilai bobot jaringan critic dalam rentang tertentu. Pendekatan ini berpotensi membatasi kapasitas representasi critic sehingga menghambat kemampuannya dalam memodelkan fungsi yang kompleks. Selain itu, pemilihan batas *clipping* yang tidak tepat dapat menyebabkan gradien menjadi terlalu lemah atau tidak stabil, yang berdampak pada ketidakstabilan proses pelatihan.

2.7 WGAN-GP

WGAN-GP merupakan pengembangan dari WGAN yang bertujuan untuk menegakkan kendala 1-Lipschitz pada critic secara lebih stabil melalui pendekatan penalti gradien. Berbeda dengan WGAN awal yang menerapkan *weight clipping* pada parameter critic, WGAN-GP menambahkan suku regularisasi berupa penalti gradien ke dalam fungsi objektif critic. Pendekatan ini terbukti mampu meningkatkan stabilitas proses pelatihan serta akurasi estimasi *Wasserstein distance*, khususnya pada jaringan saraf dengan arsitektur yang dalam (Gulrajani et al., 2017). Pada WGAN-GP, critic tetap berfungsi untuk mengaproksimasi *Wasserstein distance* antara distribusi data asli p_r dan distribusi data sintetis p_g , sebagaimana pada WGAN. Namun, kendala 1-Lipschitz tidak lagi ditegakkan melalui pembatasan nilai bobot secara eksplisit, melainkan dengan memaksa norma gradien keluaran critic terhadap masukan berada di sekitar satu pada titik-titik tertentu di ruang data. Dengan mekanisme ini, critic dapat mempertahankan kapasitas representasinya tanpa mengalami keterbatasan akibat pembatasan bobot, sehingga proses pelatihan menjadi lebih stabil dan gradien yang diteruskan ke generator tetap informatif. Arsitektur WGAN-GP secara umum ditunjukkan dalam Gambar 2.8.



Gambar 2. 8 Arsitektur WGAN-GP

2.7.1 Generator

Generator pada arsitektur WGAN-GP dirancang sebagai jaringan saraf dalam berbasis *convolutional neural network* yang memetakan vektor laten berdimensi rendah ke ruang data berdimensi tinggi. Tujuan utama generator adalah menghasilkan sampel data sintetis $\tilde{x}$ yang distribusinya semakin mendekati distribusi data asli p_r . Proses pembangkitan citra sintetis pada generator dilakukan melalui beberapa tahapan utama, yaitu *input stage*, *upsampling stage*, dan *output stage*.

1. Input Stage

Proses pembangkitan data sintetis pada generator menerima masukan berupa vektor laten yang diambil dari distribusi normal standar. Vektor laten ini kemudian diproyeksikan ke dimensi yang lebih tinggi melalui sebuah *dense layer* sehingga diperoleh representasi fitur awal yang lebih kaya. Hasil proyeksi linier tersebut selanjutnya disusun ulang menggunakan operasi *reshape* untuk membentuk representasi tensor awal atau *hidden layer* awal $h^{(0)}$, sebagaimana dirumuskan pada Persamaan (2.9).

$$h^{(0)} = \text{reshape}(W^{(p)}z + b^{(p)}) \quad (2.9)$$

Keterangan:

z : Vektor laten

$W^{(p)}$: Matriks bobot pada *dense layer* generator.

$b^{(p)}$: Vektor bias pada *dense layer* generator.

$h^{(0)}$: Representasi fitur awal generator dalam bentuk tensor.

Operasi *reshape* memungkinkan vektor hasil proyeksi linier diubah menjadi representasi tensor yang sesuai dengan struktur spasial yang dibutuhkan oleh lapisan konvolusional berikutnya. Tahap ini menghasilkan representasi awal berdimensi tinggi yang menjadi dasar bagi generator dalam mempelajari fitur-fitur kompleks selama proses pelatihan.

2. Upsampling Stage

Pada tahap ini, representasi fitur awal $h^{(0)}$ diproses melalui serangkaian blok ekspansi spasial secara hierarkis untuk meningkatkan resolusi spasial secara bertahap hingga mencapai ukuran citra target. Secara umum, transformasi pada setiap blok ekspansi ke- l dapat dirumuskan sebagaimana ditunjukkan pada Persamaan (2.10).

$$h^{(l+1)} = \sigma \left(K^{(l)} * U(h^{(l)}) \right) \quad (2.10)$$

Keterangan:

$h^{(l)}$: Representasi fitur generator pada blok ekspansi spasial ke- l .

$h^{(l+1)}$: Representasi fitur hasil transformasi pada blok ekspansi spasial ke- $l + 1$.

$U(\cdot)$: Operasi *upsampling*.

$K^{(l)}$: Kernel konvolusi.

$*$: Operasi konvolusi.

$\sigma(\cdot)$: Fungsi aktivasi nonlinier.

Tahap *upsampling* dilakukan menggunakan teknik interpolasi untuk meningkatkan resolusi spasial tanpa menambah jumlah parameter secara signifikan. Operasi konvolusi selanjutnya digunakan untuk memperhalus hasil interpolasi dan membangun struktur spasial citra

secara bertahap. Pendekatan hierarkis ini membantu generator menghasilkan citra beresolusi tinggi secara stabil serta mengurangi risiko ketidakstabilan gradien.

3. *Output Stage*

Tahap akhir generator bertujuan untuk memetakan representasi fitur hasil ekspansi spasial terakhir menjadi citra sintetis. Representasi fitur pada tahap ke- L , yang diperoleh dari proses *upsampling* berulang, diproyeksikan ke ruang citra melalui operasi konvolusi, kemudian dilewatkan ke fungsi aktivasi *hyperbolic tangent* ($\tanh$) sebagaimana dirumuskan pada Persamaan (2.11).

$$\tilde{x} = \tanh (K^{(L)} * h^{(L)}) \quad (2.11)$$

Keterangan:

$h^{(L)}$: Representasi fitur generator pada tahap ekspansi spasial terakhir.

$K^{(L)}$: Kernel konvolusi pada lapisan keluaran generator.

$\tilde{x}$: Citra sintetis yang dihasilkan oleh generator.

Penggunaan fungsi aktivasi $\tanh$ pada tahap keluaran bertujuan untuk membatasi nilai piksel citra sintetis pada rentang $[-1,1]$. Rentang ini disesuaikan dengan data latih yang telah dinormalisasi, sehingga menjaga konsistensi skala data dan mendukung stabilitas proses optimasi generator.

2.7.2 Critic

Critic pada arsitektur WGAN-GP dirancang sebagai jaringan saraf konvolusional dalam yang bertugas mengevaluasi kemiripan antara citra sintetis yang dihasilkan oleh generator dan distribusi data citra asli. Nilai keluaran critic tidak diinterpretasikan sebagai probabilitas, melainkan sebagai skor evaluasi yang mencerminkan seberapa dekat citra sintetis terhadap distribusi data asli. Proses evaluasi pada critic dilakukan melalui beberapa tahapan utama sebagaimana diuraikan sebagai berikut.

1. *Input Stage*

Proses diawali ketika critic menerima masukan berupa citra asli maupun citra sintetis yang dihasilkan oleh generator. Citra masukan tersebut diproses melalui lapisan konvolusi awal untuk mengekstraksi representasi fitur dasar. Transformasi ini dirumuskan sebagaimana ditunjukkan pada Persamaan (2.12).

$$h^{(0)} = (K^{(0)} * x) \quad (2.12)$$

Keterangan:

$h^{(0)}$: Representasi fitur awal pada critic.

$K^{(0)}$: Kernel konvolusi pada lapisan awal critic.

Tahap ini menghasilkan peta fitur awal yang memuat informasi spasial dasar, seperti tepi dan tekstur citra, yang menjadi fondasi bagi proses ekstraksi fitur lanjutan pada tahap berikutnya.

2. *Downsampling Stage*

Representasi fitur awal selanjutnya diproses melalui serangkaian blok reduksi spasial (*downsampling*) secara hierarkis untuk menurunkan resolusi spasial sekaligus meningkatkan kedalaman representasi fitur. Proses ini memungkinkan critic menangkap

informasi global citra yang relevan untuk evaluasi distribusi. Transformasi fitur pada setiap blok reduksi ke- l dirumuskan pada Persamaan (2.13).

$$h^{(l+1)} = \sigma \left(K^{(l)} * D(h^{(l)}) \right) \quad (2.13)$$

Keterangan:

$D(\cdot)$: Operasi *downsampling*.

$K^{(l)}$: Kernel konvolusi yang digunakan pada tahap reduksi spasial ke- l .

$h^{(l)}$: Representasi fitur pada tahap reduksi spasial ke- l .

$h^{(l+1)}$: Representasi fitur pada tahap reduksi spasial ke- $l + 1$.

3. Output Stage

Setelah melalui seluruh tahap reduksi spasial, representasi fitur pada tahap terakhir dipetakan menjadi satu nilai skalar yang merepresentasikan skor evaluasi critic terhadap suatu citra. Proses pemetaan ini dirumuskan sebagaimana ditunjukkan pada Persamaan (2.14).

$$f_w(x) = (K^{(L)} * h^{(L)}) \quad (2.14)$$

Keterangan:

$h^{(L)}$: Representasi fitur pada tahap reduksi spasial terakhir.

$K^{(L)}$: Kernel konvolusi pada lapisan keluaran critic.

Nilai keluaran $f_w(x)$ digunakan sebagai dasar optimasi dalam WGAN-GP untuk mengaproksimasi *Wasserstein distance* antara distribusi data asli dan data sintetis. Tidak digunakan fungsi aktivasi sigmoid pada lapisan keluaran karena nilai keluaran critic tidak dimaksudkan sebagai probabilitas klasifikasi.

2.7.3 Proses Pelatihan WGAN-GP

Proses pelatihan WGAN-GP bertujuan untuk mengoptimalkan generator dan critic secara adversarial dengan meminimalkan *Wasserstein distance* antara distribusi data sintetis dan distribusi data asli. Berbeda dengan GAN klasik yang menggunakan discriminator berbasis probabilitas, WGAN-GP menggunakan critic bernilai real untuk mengaproksimasi jarak antar distribusi, sehingga sinyal gradien yang diterima generator menjadi lebih stabil dan informatif selama proses pembelajaran. Dalam kerangka WGAN-GP, critic dilatih untuk memaksimalkan selisih nilai harapan antara keluaran critic pada data asli dan data sintetis. Pada implementasinya, nilai harapan tersebut tidak dihitung secara analitik, melainkan didekati menggunakan rata-rata empiris dari sampel dalam satu *mini-batch* berukuran M . Fungsi kerugian critic dirumuskan dalam Persamaan (2.15).

$$L_c = \frac{1}{M} \sum_{m=1}^M [f_w(\tilde{x}^{(m)}) - f_w(x^{(m)})] + \lambda \frac{1}{M} \sum_{i=1}^M \left(\|\nabla_{\hat{x}^{(m)}} f_w(\hat{x}^{(m)})\|_2 - 1 \right)^2 \quad (2.15)$$

Keterangan:

M : Jumlah sampel dalam satu *mini-batch*.

λ : Koefisien penalti gradien.

$\hat{x}^{(m)}$: Sampel interpolasi ke- m .

L_c : Fungsi *loss* critic.

Komponen pertama pada Persamaan (2.15) merepresentasikan estimasi *Wasserstein distance* antara distribusi data asli dan distribusi data sintetis. Komponen kedua merupakan *gradient penalty*, yang berfungsi untuk menegakkan kendala 1-Lipschitz pada critic secara eksplisit dan stabil. Sampel interpolasi $\hat{x}$ dibentuk sebagai kombinasi linier antara data asli dan data sintetis, sebagaimana dirumuskan pada Persamaan (2.16).

$$\hat{x} = \epsilon x + (1 - \epsilon)\tilde{x}, \quad \epsilon \sim U(0,1) \quad (2.16)$$

Keterangan:

ϵ : Bilangan acak yang diambil dari distribusi uniform standar.

Gradien keluaran critic terhadap sampel interpolasi digunakan untuk menghitung penalti gradien, yang mendorong norma gradien berada di sekitar satu. Pendekatan ini lebih unggul dibandingkan *weight clipping* pada WGAN awal karena tidak membatasi kapasitas representasi critic secara langsung. Setelah critic diperbarui, generator dilatih untuk menghasilkan data sintetis yang memperoleh skor tinggi dari critic. Fungsi kerugian generator dirumuskan sebagai Persamaan (2.17).

$$L_G = -\frac{1}{M} \sum_{m=1}^M f_w(\tilde{x}^{(m)}) \quad (2.17)$$

Keterangan:

L_G : Fungsi *loss* generator.

Fungsi kerugian ini mendorong generator untuk memaksimalkan keluaran critic terhadap data sintetis, sehingga distribusi data yang dihasilkan semakin mendekati distribusi data asli dan menghasilkan gradien yang lebih stabil dibandingkan GAN klasik.

1. Pada setiap iterasi pelatihan, parameter critic diperbarui terlebih dahulu sebanyak n_{critic} kali, sementara parameter generator dibekukan.
2. Pada setiap pembaruan critic, dilakukan *forward pass* menggunakan data asli, data sintetis, dan sampel interpolasi, diikuti dengan perhitungan fungsi kerugian critic yang mencakup estimasi *Wasserstein distance* dan *gradient penalty*.
3. Gradien fungsi kerugian critic dihitung melalui proses *backpropagation*, kemudian parameter critic diperbarui menggunakan algoritma optimisasi.
4. Setelah critic diperbarui sebanyak n_{critic} kali, generator diperbarui satu kali dengan memanfaatkan keluaran critic sebagai sinyal pembelajaran.
5. Pada fase pembaruan generator, parameter critic dibekukan dan parameter generator diperbarui dengan meminimalkan fungsi kerugian generator.

Melalui skema optimasi bergantian tersebut, critic mampu memberikan estimasi *Wasserstein distance* yang stabil dan akurat, sementara generator secara bertahap meningkatkan kualitas data sintetis yang dihasilkan. Kombinasi estimasi *Wasserstein distance* dan mekanisme *gradient penalty* menjadikan WGAN-GP lebih stabil serta mengurangi permasalahan *vanishing gradient* dan *mode collapse* yang umum terjadi pada GAN klasik.

2.7.4 Evaluasi Model WGAN-GP

Evaluasi WGAN-GP memerlukan metrik yang mampu menggambarkan kualitas dan kesesuaian citra sintetis terhadap distribusi citra asli. Pada penelitian ini, proses evaluasi model

WGAN-GP dilakukan menggunakan dua metrik yaitu FID dan SSIM. Kedua metrik ini dipilih karena mampu memberikan gambaran komprehensif terkait realisme serta integritas struktural citra yang dihasilkan oleh model WGAN-GP. FID merupakan metrik yang umum digunakan untuk mengevaluasi performa model GAN dengan membandingkan distribusi fitur antara citra asli dan citra sintetis. FID mengukur jarak Fréchet antara dua distribusi Gaussian yang dibentuk dari fitur citra asli dan citra sintetis. Secara matematis, FID dirumuskan sebagaimana ditunjukkan pada Persamaan (2.18).

$$FID = \|\mu_r - \mu_g\|^2 + Tr(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{\frac{1}{2}}) \quad (2.18)$$

Keterangan:

μ_r : Vektor rata-rata fitur citra asli.

μ_g : Vektor rata-rata fitur citra sintetis.

Σ_r : Matriks kovarians fitur citra asli.

Σ_g : Matriks kovarians fitur citra sintetis.

$Tr(\cdot)$: Operator *trace* matriks.

Nilai FID yang lebih rendah menunjukkan tingkat kesamaan distribusi fitur yang lebih tinggi antara citra sintetis dan citra asli. Nilai FID mendekati nol mengindikasikan bahwa distribusi citra sintetis semakin menyerupai distribusi citra asli, serta mencerminkan kemampuan model dalam menangkap karakteristik visual data dan mengurangi permasalahan seperti *mode collapse*. Selain FID, evaluasi juga dilakukan menggunakan SSIM, yang menilai tingkat kesamaan perseptual antara dua citra dengan mempertimbangkan aspek luminansi, kontras, dan struktur. SSIM dirumuskan sebagaimana ditunjukkan pada Persamaan (2.19).

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2.19)$$

Keterangan:

x, y : Pasangan citra yang dibandingkan.

μ_x, μ_y : Nilai rata-rata intensitas citra x dan y .

σ_x, σ_y : Varians intensitas citra x dan y .


σ_{xy} : Kovarians antara citra x dan y .

C_1, C_2 : Konstanta stabilisasi untuk menghindari pembagian dengan nol.

Nilai SSIM berada pada rentang 0 hingga 1, di mana nilai yang mendekati 1 menunjukkan tingkat kemiripan visual dan struktural yang semakin tinggi antara citra sintetis dan citra asli. Metrik ini sangat relevan untuk citra CXR karena struktur anatomi utama harus tetap terjaga agar citra sintetis memiliki nilai klinis dan visual yang memadai (Chugh, 2023).

2.8 CNN


CNN merupakan salah satu jenis jaringan saraf tiruan yang banyak digunakan dalam pengolahan citra karena kemampuannya dalam mengekstraksi fitur secara otomatis dari data masukan. CNN memanfaatkan struktur spasial citra melalui operasi konvolusi, sehingga mampu mempelajari pola visual seperti tepi, tekstur, dan bentuk objek secara hierarkis. Arsitektur CNN secara umum terdiri dari beberapa lapisan utama sebagaimana ditunjukkan pada Gambar 2.9.



Gambar 2. 9 Arsitektur CNN

2.8.1 Convolutional Layer

Convolutional layer merupakan lapisan utama pada CNN yang berfungsi untuk mengekstraksi fitur dari citra masukan menggunakan filter atau kernel berukuran kecil yang digeser secara sistematis di seluruh citra. Proses ini menghasilkan peta fitur (*feature map*) yang merepresentasikan respons citra terhadap pola tertentu yang dipelajari oleh kernel, seperti tepi, sudut, atau tekstur.



Gambar 2. 10 Ilustrasi Proses Konvolusi

Ilustrasi proses konvolusi dua dimensi pada CNN ditunjukkan pada Gambar 2.10. Pada setiap posisi pergeseran kernel, dilakukan operasi perkalian elemen-elemen antara nilai piksel citra masukan dan bobot kernel, kemudian seluruh hasil perkalian dijumlahkan untuk menghasilkan satu nilai pada peta fitur. Secara matematis, operasi konvolusi dua dimensi dapat dirumuskan pada Persamaan (2.20).

$$F_{(i,j)} = \sum_{u=0}^{U-1} \sum_{v=0}^{V-1} X_{(i+u,j+v)} K_{(u,v)} \quad (2.20)$$

Keterangan:

$K_{(u,v)}$: Kernel konvolusi berukuran $U \times V$.

$F_{(i,j)}$: Nilai *feature map* hasil konvolusi pada posisi (i,j) .

U : Tinggi kernel konvolusi.


V : Lebar kernel konvolusi.

Proses konvolusi ini dilakukan secara berulang pada seluruh posisi citra masukan sehingga terbentuk peta fitur yang menyoroti karakteristik tertentu dari citra. Penggunaan beberapa kernel yang berbeda dalam satu lapisan konvolusi memungkinkan CNN mengekstraksi

berbagai jenis fitur secara simultan, di mana setiap kernel menghasilkan satu peta fitur yang merepresentasikan pola yang berbeda.

2.8.2 Pooling Layer

Pooling digunakan untuk mereduksi dimensi spasial peta fitur (*feature map*) yang dihasilkan oleh lapisan konvolusi. Tujuan utama dari pooling adalah mengurangi jumlah parameter dan beban komputasi, sekaligus meningkatkan ketahanan model terhadap variasi kecil pada posisi objek dalam citra. Dengan melakukan reduksi dimensi, *pooling* membantu mencegah *overfitting* dan mempercepat proses pelatihan jaringan.



Gambar 2. 11 Ilustrasi Proses *Pooling* pada CNN

Ilustrasi proses pooling pada CNN ditunjukkan pada Gambar 2.11, di mana sebuah jendela pooling digeser pada peta fitur masukan untuk menghasilkan peta fitur keluaran dengan resolusi yang lebih kecil. Dua metode pooling yang umum digunakan adalah *max pooling* dan *average pooling*.

1. Max Pooling

Pada metode max pooling, nilai maksimum dari setiap area lokal pada peta fitur masukan dipilih sebagai nilai keluaran. Operasi max pooling secara matematis dirumuskan pada Persamaan (2.21).

$$P_{(i,j)} = \max_{m,n} F_{(i+p,j+q)} \quad (2.21)$$

Keterangan:

$P_{(i,j)}$: Nilai *feature map* keluaran hasil pooling pada posisi (i,j) .

p, q : Indeks posisi dalam jendela pooling.

2. Average Pooling

Pada metode average pooling, nilai keluaran diperoleh dengan menghitung rata-rata dari seluruh nilai dalam area pooling. Operasi average pooling secara matematis dirumuskan pada Persamaan (2.22).

$$P_{(i,j)} = \frac{1}{k \times k} \sum_{p=0}^{k-1} \sum_{q=0}^{k-1} F_{(i+p,j+q)} \quad (2.22)$$

Keterangan:

k : Ukuran jendela pooling.

2.8.3 Fungsi Aktivasi

Fungsi aktivasi diterapkan pada jaringan saraf untuk menambahkan sifat non-linearitas pada model. Keberadaan non-linearitas memungkinkan CNN mempelajari hubungan yang kompleks antara fitur masukan dan keluaran. Dalam penelitian ini, beberapa fungsi aktivasi yang umum digunakan pada CNN dan model generatif, khususnya GAN dan WGAN-GP, meliputi fungsi tanh, Rectified Linear Unit (ReLU), Leaky ReLU, dan softmax.

1. Fungsi tanh

Fungsi aktivasi tanh dinotasikan pada Persamaan (2.23).

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.23)$$

Keterangan:

e : Bilangan euler.

Fungsi tanh menghasilkan nilai keluaran dalam rentang $[-1,1]$, sehingga mampu menangani masukan yang bersifat negatif maupun positif. Selain itu, fungsi ini bersifat *zero-centered*, yang dapat membantu meningkatkan stabilitas proses optimasi.

2. Fungsi ReLU

Fungsi aktivasi ReLU dinotasikan pada Persamaan (2.24).

$$f(x) = \max(0, x) \quad (2.24)$$

Fungsi ReLU menghasilkan nilai keluaran nol untuk masukan negatif dan mempertahankan nilai masukan positif tanpa perubahan. ReLU memiliki komputasi yang sederhana serta efektif dalam mengurangi permasalahan *vanishing gradient*, sehingga mampu mempercepat dan menstabilkan proses pelatihan jaringan saraf. Oleh karena itu, ReLU banyak digunakan pada lapisan tersembunyi CNN.

3. Fungsi Leaky ReLU

Leaky ReLU merupakan pengembangan dari fungsi ReLU yang bertujuan untuk mengatasi permasalahan *dying ReLU*, yaitu kondisi ketika neuron menjadi tidak aktif secara permanen. Fungsi Leaky ReLU dinotasikan pada Persamaan (2.25).

$$f(x) = \begin{cases} x, & x \geq 0 \\ \alpha x, & x < 0 \end{cases} \quad (2.25)$$

Keterangan:

α : Konstanta kecil bernilai positif yang mengatur kemiringan pada daerah negatif (umumnya $\alpha = 0.01$ atau 0.2).

Dengan memberikan gradien kecil pada masukan negatif, Leaky ReLU menjaga aliran gradien tetap berjalan selama pelatihan. Fungsi ini banyak digunakan pada lapisan tersembunyi generator dan critic dalam WGAN-GP untuk meningkatkan stabilitas pembelajaran.

4. Fungsi softmax

Fungsi softmax digunakan pada lapisan keluaran jaringan saraf untuk menghasilkan distribusi probabilitas pada tugas klasifikasi multikelas. Fungsi ini memetakan vektor nilai

masukan (*logit*) menjadi nilai probabilitas untuk setiap kelas, dengan jumlah seluruh probabilitas bernilai satu. Secara matematis, fungsi softmax dinotasikan pada Persamaan (2.26).

$$\text{softmax}(z_c) = \frac{e^{z_c}}{\sum_{s=1}^C e^{z_s}} \quad (2.26)$$

Keterangan:

z_c : Nilai logit untuk kelas ke- c .


C : Jumlah kelas yang diprediksi.

s : Indeks pembantu untuk menjumlahkan nilai seluruh kelas agar hasilnya menjadi probabilitas.

Fungsi softmax menghasilkan nilai keluaran dalam rentang $[0,1]$ yang dapat diinterpretasikan sebagai probabilitas keanggotaan suatu kelas. Kelas dengan nilai probabilitas tertinggi dipilih sebagai hasil prediksi akhir. Oleh karena itu, fungsi softmax umum digunakan pada lapisan keluaran CNN untuk permasalahan klasifikasi multikelas.

2.8.4 Fully Connected Layer

Lapisan *fully connected* merupakan bagian akhir dari arsitektur CNN yang berfungsi untuk mengintegrasikan seluruh fitur hasil ekstraksi dan menghasilkan keluaran akhir, seperti prediksi kelas pada tugas klasifikasi. Setelah melalui beberapa lapisan konvolusi dan pooling, peta fitur yang dihasilkan masih berbentuk tensor multidimensi sehingga perlu dikonversi menjadi vektor satu dimensi sebelum diproses oleh lapisan *fully connected*. Ilustrasi proses *flattening* dan koneksi penuh pada lapisan ini ditunjukkan pada Gambar 2.12.



Gambar 2. 12 Ilustrasi Proses flattening

Proses konversi tersebut dilakukan melalui tahap *flattening*, yaitu dengan menyusun seluruh elemen peta fitur menjadi sebuah vektor satu dimensi tanpa mengubah nilai elemen di dalamnya. Vektor hasil *flattening* selanjutnya diproses oleh lapisan *fully connected*, di mana setiap neuron terhubung dengan seluruh elemen vektor masukan. Proses pemetaan ini dilakukan melalui transformasi linier yang melibatkan bobot dan bias, yang dirumuskan pada Persamaan (2.27).

$$z = Wx + b \quad (2.27)$$

Keterangan:

W : Matriks bobot pada lapisan *fully connected*.

b : Vektor bias.

z : Keluaran linear dari lapisan *fully connected* sebelum fungsi aktivasi diterapkan.

Lapisan *fully connected* bertugas mempelajari kombinasi global dari fitur-fitur yang telah diekstraksi pada tahap sebelumnya. Transformasi linier pada lapisan ini menghasilkan representasi fitur tingkat tinggi yang siap dipetakan ke ruang keluaran. Keluaran dari lapisan *fully connected* selanjutnya dilewatkan ke fungsi aktivasi pada lapisan *output*, yang disesuaikan dengan jenis tugas yang dikerjakan. Pada tugas klasifikasi multikelas, fungsi aktivasi *softmax* digunakan untuk menghasilkan distribusi probabilitas bagi setiap indeks kelas c , sebagaimana dirumuskan pada Persamaan (2.25). Kelas dengan nilai probabilitas tertinggi kemudian dipilih sebagai hasil prediksi akhir model, yang merepresentasikan label kondisi klinis paru-paru y_n untuk citra ke- n . Dalam penelitian ini, nilai y_n tersebut merujuk pada salah satu dari empat kategori diagnosis, yaitu 1 (Normal), 2 (COVID-19), 3 (Pneumonia Bakterial), atau 4 (Pneumonia Viral).

Keterangan:

n : Indeks urutan citra CXR dalam dataset ($n = 1, 2, \dots, N$).

N : Jumlah citra CXR dalam dataset.

2.8.5 Fungsi Loss

Fungsi *loss* merupakan komponen penting dalam pelatihan CNN yang digunakan mengukur tingkat kesalahan antara hasil prediksi model dan nilai sebenarnya. Nilai *loss* memberikan umpan balik selama proses pelatihan sehingga parameter jaringan dapat diperbarui agar prediksi model semakin mendekati target yang diinginkan. Pada tugas klasifikasi, fungsi *loss* yang umum digunakan adalah *cross-entropy loss* karena mampu mengukur perbedaan antara distribusi probabilitas hasil prediksi model dan distribusi label sebenarnya. Semakin kecil nilai *cross-entropy loss*, semakin dekat distribusi prediksi model dengan distribusi label yang benar. Pada kasus klasifikasi multikelas, *cross-entropy loss* dirumuskan pada Persamaan (2.28).

$$L = - \sum_{c=1}^C y_c \log(p_c) \quad (2.28)$$

Keterangan:

y_c : Label sebenarnya untuk kelas ke- c .

p_c : Probabilitas prediksi model untuk kelas ke- c .

L : Fungsi *loss* CNN.

Fungsi *cross-entropy loss* mendorong model memberikan probabilitas tinggi pada kelas yang benar dan probabilitas rendah pada kelas yang salah, sehingga efektif meningkatkan performa model pada tugas klasifikasi multikelas.

2.8.6 Fungsi Optimasi

Fungsi optimasi pada CNN digunakan untuk memperbarui bobot dan bias jaringan agar nilai fungsi *loss* dapat diminimalkan. Proses optimasi dilakukan melalui mekanisme

backpropagation, di mana gradien fungsi *loss* dihitung terhadap setiap parameter jaringan, kemudian parameter tersebut diperbarui secara iteratif menggunakan algoritma optimasi berbasis *gradient descent*. Pada penelitian ini, algoritma optimasi yang digunakan adalah Adam (*Adaptive Moment Estimation*) karena mampu mempercepat konvergensi dan menjaga stabilitas pelatihan. Adam mengombinasikan estimasi momen pertama dan momen kedua dari gradien fungsi *loss*. Estimasi momen pertama dinyatakan pada Persamaan (2.29), sedangkan estimasi momen kedua dinyatakan pada Persamaan (2.30)

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla L(w_t) \quad (2.29)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) (\nabla L(w_t))^2 \quad (2.30)$$

Pembaruan parameter jaringan dilakukan menggunakan Persamaan (2.31), yang memanfaatkan kedua estimasi momen tersebut untuk menyesuaikan langkah pembaruan parameter secara adaptif pada setiap iterasi pelatihan.

$$w_{t+1} = w_t - \frac{\eta}{\sqrt{v_t} + \epsilon} m_t \quad (2.31)$$


Keterangan:

- w_t : Parameter model pada iterasi ke- t .
- m_t : Estimasi momen pertama (rata-rata gradien).
- v_t : Estimasi momen kedua (rata-rata kuadrat gradien).
- β_1, β_2 : Koefisien momentum untuk momen pertama dan kedua.
- η : *Learning rate*.
- $\nabla L(w_t)$: Gradien fungsi *loss* terhadap parameter.

2.8.7 ResNet-50

CNN telah menunjukkan kinerja yang baik dalam pengolahan citra. Namun, prosesnya membutuhkan banyak data latih, terutama pada skema pelatihan dari awal, sehingga rentan terhadap *overfitting* ketika data terbatas. Sebagai solusi, pendekatan *transfer learning* digunakan dengan memanfaatkan model pralatih (*pre-trained model*) yang telah dilatih pada dataset berskala besar. Pendekatan ini memungkinkan model beradaptasi pada tugas spesifik dengan data terbatas secara lebih efektif. Dalam penelitian ini, ResNet50 dipilih sebagai model klasifikasi utama karena telah terbukti memberikan performa yang stabil dan unggul pada berbagai tugas klasifikasi citra medis, termasuk citra CXR.

ResNet-50 dirancang sebagai jaringan saraf konvolusional dalam yang mengadopsi konsep *residual learning* melalui mekanisme *shortcut connection*. Berbeda dengan CNN konvensional yang secara langsung mempelajari fungsi pemetaan dari input ke output, ResNet-50 mempelajari fungsi residu, yaitu selisih antara *input* dan *output* lapisan. Mekanisme ini memungkinkan aliran gradien tetap stabil selama proses pelatihan, sehingga jaringan dengan kedalaman tinggi dapat dilatih secara efektif tanpa mengalami degradasi performa. (Nashrullah et al., 2020).



Gambar 2. 13 Arsitektur ResNet-50

Berdasarkan arsitektur yang ditunjukkan pada Gambar 2.13, ResNet-50 memproses citra masukan melalui beberapa tahapan utama secara berurutan. Proses diawali dengan lapisan konvolusi awal berukuran kernel 7×7 dan *stride* 2 untuk mengekstraksi fitur dasar seperti tepi dan tekstur, yang kemudian diikuti oleh *batch normalization*, fungsi aktivasi ReLU, serta *max pooling* berukuran 3×3 dengan *stride* 2 untuk mereduksi resolusi spasial dan beban komputasi. Selanjutnya, jaringan memasuki rangkaian blok residual yang terdiri dari *convolutional block* dan *identity block*. *Convolutional block* digunakan pada awal setiap tahap untuk menyesuaikan dimensi data ketika resolusi spasial diperkecil dan jumlah kanal fitur ditingkatkan, sedangkan *identity block* digunakan untuk memperdalam jaringan tanpa mengubah dimensi data. Kombinasi kedua blok ini memungkinkan pendalaman representasi fitur secara bertahap sekaligus menjaga kestabilan aliran gradien melalui *shortcut connection*. Pada tahap akhir, seluruh peta fitur dirangkum menggunakan *global average pooling* menjadi sebuah vektor representasi yang padat. Vektor ini kemudian diteruskan ke lapisan *fully connected* dan lapisan keluaran. Pada tugas klasifikasi multikelas, fungsi aktivasi *softmax* digunakan pada lapisan keluaran untuk menghasilkan distribusi probabilitas pada setiap kelas. Proses pelatihan ResNet50 dilakukan dengan meminimalkan fungsi kerugian *categorical cross-entropy*, sementara mekanisme *shortcut connection* berperan penting dalam menjaga stabilitas proses optimasi dan memastikan pembaruan bobot tetap efektif meskipun jaringan memiliki kedalaman yang besar.

2.8.8 Evaluasi Model Klasifikasi

Performa model klasifikasi dievaluasi menggunakan *confusion matrix*. Berdasarkan matriks ini, beberapa metrik yang menggambarkan efektivitas model, antara lain *sensitivity*, *precision*, *accuracy*, dan *F1-score* dapat dihitung. Kelas positif didefinisikan sebagai kondisi utama yang ingin dideteksi oleh model, sedangkan kelas negatif merupakan kondisi selain kelas positif. Sebagai contoh, pada klasifikasi citra medis, kelas positif dapat merepresentasikan citra yang mengandung indikasi penyakit, sementara kelas negatif menunjukkan citra normal.

Sensitivity mengukur kemampuan model dalam mendeteksi seluruh data yang termasuk kelas positif, sehingga menunjukkan seberapa banyak kasus positif yang berhasil dikenali oleh model. *Sensitivity* dirumuskan pada Persamaan (2.32).

$$Sensitivity = \frac{TP}{TP + FN} \quad (2.32)$$

Precision menunjukkan kemampuan model dalam mendeteksi seluruh data yang termasuk kelas positif, sehingga menunjukkan seberapa banyak kasus positif yang berhasil dikenali oleh model. *Precision* dirumuskan pada Persamaan (2.33).

$$Precision = \frac{TP}{TP + FP} \quad (2.33)$$

Accuracy menggambarkan tingkat ketepatan model secara keseluruhan dalam melakukan prediksi, baik pada kelas positif maupun negatif. *Accuracy* dirumuskan pada Persamaan (2.34).

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.34)$$

F1-score merupakan ukuran yang menggabungkan *sensitivity* dan *precision* untuk memberikan gambaran keseimbangan antara kemampuan deteksi dan ketepatan prediksi positif. *F1-score* dirumuskan pada Persamaan (2.35).

$$F1 - score = 2 \times \frac{Precision \times Sensitivity}{Precision + Sensitivity} \quad (2.35)$$

Keterangan:

TP: *true positive*, data yang benar-benar termasuk kelas positif dan berhasil diprediksi sebagai positif oleh model.

TN: *true negative*, data yang termasuk kelas negatif dan berhasil diprediksi sebagai negatif.

FP: *false positive*, data yang sebenarnya termasuk kelas negatif tetapi keliru diprediksi sebagai positif

FN: *false negative*, data yang sebenarnya termasuk kelas positif tetapi keliru diprediksi sebagai negatif

2.9 Hyperparameter Penelitian

Hyperparameter adalah parameter yang ditetapkan oleh pengembang sebelum proses pelatihan model dimulai dan nilainya tidak berubah secara otomatis selama proses pembelajaran berlangsung. Berbeda dengan bobot (parameter internal) yang dipelajari model dari data, *hyperparameter* berfungsi sebagai konfigurasi eksternal yang mengendalikan jalannya proses optimasi, menjaga kestabilan pelatihan, serta menentukan efisiensi komputasi untuk mencapai kinerja model yang optimal. Hyperparameter umum yang digunakan dalam penelitian ini sebagai berikut.

- **Learning Rate:** Parameter yang mengatur besar langkah pembaruan bobot pada setiap iterasi optimasi. Nilai learning rate memengaruhi kecepatan konvergensi serta kestabilan proses pelatihan.
- **Epoch:** Jumlah pengulangan pelatihan, di mana seluruh data pelatihan diproses satu kali secara utuh dalam satu epoch.
- **Batch Size:** Jumlah sampel data yang digunakan dalam satu kali proses pembaruan bobot. Batch size memengaruhi kestabilan gradien dan kebutuhan memori selama pelatihan.
- **Dropout Rate:** Parameter yang menentukan probabilitas setiap unit atau neuron untuk dinonaktifkan sementara secara acak selama proses pelatihan. Hal ini berfungsi sebagai teknik regularisasi untuk mencegah *overfitting* dan meningkatkan kemampuan generalisasi model.

Selain hyperparameter umum, WGAN-GP memiliki hyperparameter khusus yang berkaitan dengan kestabilan pelatihan model generatif sebagai berikut.

- **Dimensi Latent Vector:** Ukuran vektor noise yang menjadi masukan bagi generator. Dimensi ini memengaruhi kemampuan generator dalam merepresentasikan variasi dan keragaman citra sintetis yang dihasilkan.
- **Koefisien Gradient Penalty (λ):** Parameter yang mengatur kekuatan penalti gradien dalam fungsi kerugian critic, dengan tujuan memastikan norma gradien mendekati satu sehingga kendala 1-Lipschitz dapat terpenuhi secara stabil.
- **Critic Iterations (n_{Critic}):** Jumlah iterasi pelatihan jaringan *critic* per satu kali iterasi generator untuk memastikan estimasi jarak Wasserstein yang akurat.

Pengaturan *hyperparameter* tersebut dilakukan secara terkontrol untuk memperoleh keseimbangan antara stabilitas pelatihan, kualitas citra sintetis yang dihasilkan, dan performa model klasifikasi pada tahap selanjutnya.

BAB 3

METODE PENELITIAN

3.1 Sumber Data

Penelitian ini menggunakan data sekunder berupa citra CRX yang bersumber dari platform *Mendeley Data* melalui dataset berjudul “*Curated Dataset for COVID-19 Posterior-Anterior Chest Radiography Images (X-Rays)*”. *Mendeley Data* merupakan penyedia sumber data terbuka yang umum digunakan untuk mendukung proyek *machine learning* dan sistem kecerdasan buatan. Dataset yang digunakan terdiri. Data tersebut mencakup empat kategori kelas, yaitu kondisi normal, COVID-19, pneumonia bakterial, dan pneumonia viral. Adapun dari 9.208 citra dalam format JPG dataset ini disusun untuk mendukung pengembangan penelitian klasifikasi penyakit infeksi paru berbasis pendekatan *deep learning*, di mana setiap citra merepresentasikan kondisi patologi paru-paru dari pasien yang berbeda.

3.2 Variabel Penelitian

Variabel yang digunakan dalam penelitian ini berupa citra CRX yang merepresentasikan empat kondisi klinis paru-paru pasien, sebagaimana ditunjukkan pada Tabel 3.1. Adapun definisi operasional dari variabel tersebut telah dijabarkan secara rinci pada subbab 2.2.

Tabel 3. 1 Jumlah Gambar Menurut Kondisi Paru-Paru

No	Kondisi Klinis Paru-Paru	Jumlah Gambar
1.	Normal	3270
2.	COVID-19	1281
3.	Pneumonia Bacterial	3001
4.	Pneumonia Viral	1656

Citra CRX yang digunakan bersifat *grayscale*, sehingga setiap piksel memiliki satu nilai intensitas dengan rentang tertentu. Berdasarkan citra yang digunakan, variabel penelitian dirinci sebagaimana ditunjukkan pada Tabel 3.2.

Tabel 3. 2 Variabel Penelitian

Variabel	Keterangan	Skala Pengukuran Data	Nilai
$X_{n,i,j}$	Nilai intensitas piksel pada citra ke- n pada koordinat baris i dan kolom j .	Interval	$0 \leq X_{n,i,j} \leq 255$
Y_n	Label kondisi klinis (target) untuk citra ke- n .	Nominal	1,2,3,4

3.3 Struktur Data

Struktur data yang digunakan dalam proses klasifikasi ditampilkan pada Tabel 3.3. Citra CRX pada penelitian ini merupakan citra *grayscale* dua dimensi dengan satu kanal intensitas, sehingga struktur data yang dihasilkan hanya memiliki satu lapisan kanal dan disusun berdasarkan nilai intensitas piksel pada setiap posisi koordinat dalam citra.

Tabel 3. 3 Struktur Data dalam Proses Klasifikasi

Citra ke- n	$X_{(n,0,0)}$	$X_{(n,0,1)}$	...	$X_{(n,i,j)}$	...	$X_{(n,255,255)}$	Y_n
1	$X_{(1,0,0)}$	$X_{(1,0,1)}$	...	$X_{(1,i,j)}$	...	$X_{(1,255,255)}$	Y_1
2	$X_{(2,0,0)}$	$X_{(2,0,1)}$	...	$X_{(2,i,j)}$	...	$X_{(2,255,255)}$	Y_2
3	$X_{(3,0,0)}$	$X_{(3,0,1)}$	...	$X_{(3,i,j)}$	...	$X_{(3,255,255)}$	Y_3
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
9208	$X_{(9208,0,0)}$	$X_{(9208,0,1)}$	...	$X_{(9208,i,j)}$	...	$X_{(9208,255,255)}$	Y_{9208}

3.4 Langkah Analisis


Penelitian ini mengintegrasikan WGAN-GP dan ResNet-50 untuk mengklasifikasikan kondisi klinis paru-paru berdasarkan citra CXR. Analisis di dalam penelitian ini terdiri dari tahapan-tahapan berikut.

1. Mengunduh data citra CXR dari platform *Mendeley Data* melalui dataset yang berjudul “*Curated Dataset for COVID-19 Posterior-Anterior Chest Radiography Images (X-Rays)*”.
2. Melakukan *preprocessing* pada seluruh citra dengan menyesuaikan ukuran citra serta menormalisasi nilai piksel agar sesuai dengan kebutuhan *input* model.
3. Membagi dataset menjadi 80% data latih, 10% data validasi, dan 10% data uji pada setiap kelas.
4. Melatih model ResNet-50 menggunakan data latih asli dengan menerapkan augmentasi data konvensional untuk memperoleh performa awal (*baseline*), dengan tahapan:
 - a. Menyiapkan generator citra menggunakan *ImageDataGenerator* yang menerapkan normalisasi serta augmentasi konvensional, seperti rotasi, pergeseran horizontal dan vertikal, pembalikan horizontal, dan *zoom*.
 - b. Menggunakan ResNet-50 dengan bobot awal dari *ImageNet* sebagai *base model*.
 - c. Menerapkan strategi *fine-tuning* pada beberapa lapisan terakhir model.
 - d. Menambahkan lapisan *Global Average Pooling*, *dense layer* dengan aktivasi *ReLU*, serta *dropout* untuk mencegah *overfitting*.
 - e. Menyusun lapisan *output* dengan aktivasi *softmax* sesuai jumlah kategori kondisi paru-paru.
 - f. Menetapkan *hyperparameter* pelatihan model, yang meliputi *learning rate*, *batch size*, jumlah *epoch*, dan *dropout rate*.
 - g. Mengompilasi model menggunakan *optimizer Adam*, fungsi *loss categorical_crossentropy*, dan metrik *accuracy*.
 - h. Melatih model menggunakan data latih dan data validasi sesuai *hyperparameter* yang telah ditetapkan.
5. Mengevaluasi model ResNet-50 hasil pelatihan data asli menggunakan data uji dengan menghitung metrik *accuracy*, *precision*, *recall*, dan *F1-score* sebagai performa awal (*baseline*).
6. Mengidentifikasi kategori kondisi paru-paru yang memiliki jumlah sampel paling sedikit sebagai target augmentasi data sintetis.
7. Melakukan *preprocessing* data latih untuk pelatihan WGAN-GP, meliputi penyesuaian ukuran citra dan normalisasi nilai piksel agar sesuai dengan standar *input* model generatif.
8. Membangun arsitektur generator WGAN-GP, dengan tahapan:
 - a. Menerima *latent vector* sebagai *input* awal pembentukan fitur citra.
 - b. Meneruskan *input* ke *dense layer* dan melakukan *reshape* menjadi tensor fitur awal.
 - c. Menerapkan *batch normalization* dan fungsi aktivasi *LeakyReLU*.
 - d. Memperbesar ukuran tensor secara bertahap melalui lapisan *upsampling* dan *Conv2D*.
 - e. Menggunakan fungsi aktivasi *tanh* pada lapisan terakhir untuk menghasilkan citra sintetis dengan rentang nilai piksel yang menyerupai citra asli.
9. Membangun arsitektur critic WGAN-GP, dengan tahapan:
 - a. Menerima citra CXR dalam format *grayscale*.
 - b. Mengekstraksi fitur spasial menggunakan rangkaian lapisan *Conv2D* dengan pengaturan kernel dan *stride* tertentu.
 - c. Menerapkan fungsi aktivasi *LeakyReLU*.
 - d. Melakukan *flatten* dan meneruskan hasilnya ke *dense layer* tunggal untuk menghasilkan skor realitas citra.

10. Menetapkan *hyperparameter* model WGAN-GP serta fungsi *Gradient Penalty* untuk menjaga stabilitas gradien selama proses pelatihan.
11. Melatih model WGAN-GP selama sejumlah *epoch* dengan pembaruan bobot Generator dan Critic secara bergantian, serta memantau kualitas citra sintetis melalui perhitungan metrik FID, SSIM, dan visualisasi contoh citra.
12. Menyimpan model WGAN-GP terbaik.
13. Menghasilkan citra sintetis menggunakan model WGAN-GP terbaik dan menggabungkannya dengan data latih asli sehingga membentuk dataset latih teraugmentasi.
14. Melatih ulang model ResNet-50 menggunakan dataset gabungan dengan menerapkan augmentasi data konvensional yang sama seperti pada pelatihan *baseline* serta menggunakan konfigurasi *hyperparameter* yang identik.
15. Mengevaluasi model ResNet-50 hasil pelatihan ulang menggunakan data uji yang sama untuk memperoleh nilai *accuracy*, *precision*, *recall*, dan *F1-score*.
16. Membandingkan hasil evaluasi model ResNet-50 sebelum dan sesudah penerapan augmentasi data sintetis WGAN-GP.
17. Menarik kesimpulan berdasarkan hasil perbandingan performa model.

3.5 Diagram Alir Penelitian

Langkah-langkah analisis pada penelitian ini divisualisasikan menggunakan diagram alir, sehingga mempermudah pemahaman terhadap urutan tahapan, keterkaitan antarproses, dan alur kerja secara keseluruhan.



Gambar 3. 1 Diagram Alir Penelitian

3.6 Jadwal Penelitian

Jadwal penelitian disusun untuk memberikan gambaran rinci mengenai tahapan kegiatan selama penelitian. Jadwal ini disajikan dalam Tabel 3.4, yang bertujuan memastikan setiap tahap penelitian berjalan secara terstruktur, tepat waktu, dan dapat dipantau secara berkala. Waktu pelaksanaan setiap kegiatan dibagi berdasarkan tahun, bulan, dan minggu, sehingga mempermudah pemantauan dan evaluasi progres penelitian.

Tabel 3. 4 Jadwal Penelitian

Kegiatan	Waktu Penelitian																											
	2025				2026																							
	Desember				Januari				Februari				Maret				April				Mei				Juni			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Menentukan topik penelitian																												
Melakukan studi literatur																												
Mengumpulkan data																												
Menyusun dan bimbingan proposal TA																												
Seminar proposal TA																												
Revisi dan finalisasi proposal TA																												
Membuat model klasifikasi ResNet50																												
Melatih model ResNet50																												
Evaluasi model ResNet50																												
Membuat model WGAN-GP																												
Melatih model WGAN-GP																												
Evaluasi model WGAN-GP																												
Menentukan model WGAN-GP terbaik																												
Membuat model klasifikasi ResNet50 dengan augmentasi WGAN-GP																												
Melatih model klasifikasi ResNet50 dengan augmentasi WGAN-GP																												

Tabel 3. 4 (lanjutan)

Kegiatan	Waktu Penelitian																											
	2025				2026																							
	Desember				Januari				Februari				Maret				April				Mei				Juni			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Evaluasi model klasifikasi ResNet50 dengan augmentasi WGAN-GP																												
Menentukan model terbaik																												
Analisis hasil dan pembahasan																												
Menyusun dan bimbingan laporan TA																												
Seminar hasil dan ujian TA																												
Revisi dan finalisasi laporan TA																												

DAFTAR PUSTAKA

- Alamudin, M. F., Mazdadi, M. I., Nugroho, R. A., Saragih, T. H., Muliadi, M., & Athavale, V. A. (2025). Implementation of the Wasserstein Generative Adversarial Network with Gradient Penalty (WGAN-GP) Method to Address Class Imbalance in Alzheimer's Disease Magnetic Resonance Imaging (MRI) Datasets. *Indonesian Journal of Electronics, Electromedical Engineering, and Medical Informatics*, 7(3), 526–538. <https://doi.org/10.35882/ijeemi.v7i3.109>
- Arjovsky, M., Chintala, S., & Bottou, L. (2017). *Wasserstein GAN*. <http://arxiv.org/abs/1701.07875>
- Baker, Q. B., Hammad, M., Al-Smadi, M., Al-Jarrah, H., Al-Hamouri, R., & Al-Zboon, S. A. (2024). Enhanced COVID-19 Detection from X-ray Images with Convolutional Neural Network and Transfer Learning. *Journal of Imaging*, 10(10). <https://doi.org/10.3390/jimaging10100250>
- Batah, S. S., & Fabro, A. T. (2021). Pulmonary pathology of ARDS in COVID-19: A pathological review for clinicians. *Respiratory Medicine*, 176(November 2020), 106239. <https://doi.org/10.1016/j.rmed.2020.106239>
- Chugh, L. (2023). Addressing data scarcity and class imbalance in Alzheimer's. In *International Journal of Engineering Research and Technology*.
- Clementi, N., Ghosh, S., De Santis, M., Castelli, M., Criscuolo, E., Zanoni, I., Clementi, M., & Mancini, N. (2021). Viral respiratory pathogens and lung injury. *Clinical Microbiology Reviews*, 34(3). <https://doi.org/10.1128/CMR.00103-20>
- Cohen, G., & Giryas, R. (2023). Generative Adversarial Networks. *Machine Learning for Data Science Handbook: Data Mining and Knowledge Discovery Handbook, Third Edition*, 375–400. https://doi.org/10.1007/978-3-031-24628-9_17
- Cohen, M., Levine, S. M., & Zar, H. J. (2022). World Lung Day: impact of “the big 5 lung diseases” in the context of COVID-19. *American Journal of Physiology - Lung Cellular and Molecular Physiology*, 323(3), L338–L340. <https://doi.org/10.1152/ajplung.00261.2022>
- Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). *Generative Adversarial Nets*.
- Gulrajani, I., Ahmed, F., Arjovsky, M., Dumoulin, V., & Courville, A. (2017). Improved training of wasserstein GANs. *Advances in Neural Information Processing Systems, 2017-Decem*, 5768–5778.
- Huang, H., Cai, S., Li, Y., Li, Y., Fan, Y., Li, L., Lei, C., Tang, X., Hu, F., Li, F., & Deng, X. (2020). Prognostic Factors for COVID-19 Pneumonia Progression to Severe Symptoms Based on Earlier Clinical Features: A Retrospective Analysis. *Frontiers in Medicine*, 7(October), 1–7. <https://doi.org/10.3389/fmed.2020.557453>
- Kaur, A. (2025). *Overview of Digital Image Processing*. 7(2), 1–6.
- Lestari, D. (2025). PENERAPAN CONVOLUTIONAL NEURAL NETWORK UNTUK KLASIFIKASI PNEUMONIA BAKTERI DAN VIRUS MENGGUNAKAN GAMBAR X-RAY DADA. *UNIVERSITAS ISLAM NEGERI SULTAN SYARIF KASIM RIAU*.

- Lukito, J. (2020, September 7). “*Silent Hypoxia*” Pada COVID-19. KALBE MED. <https://kalbemed.com/article/silent-hypoxia-pada-covid-19-1>
- Maquen-Niño, G. L. E., Nuñez-Fernandez, J. G., Taquila-Calderon, F. Y., Adrianzén-Olano, I., De-La-cruz-vdv, P., & Carrión-Barco, G. (2024). Classification Model Using Transfer Learning for the Detection of Pneumonia in Chest X-Ray Images. *International Journal of Online and Biomedical Engineering*, 20(5), 150–161. <https://doi.org/10.3991/ijoe.v20i05.45277>
- Nashrullah, F., Wibowo, S. A., & Budiman, G. (2020). Investigasi Parameter Epoch Pada Arsitektur ResNet-50 Untuk Klasifikasi Pornografi. *Journal of Computer, Electronic, and Telecommunication*, 1(1), 1–8.
- Office, I. H., Arifuddin, R., & Hidayatulail, B. F. (2024). *Klasifikasi Pneumonia Menggunakan Convolutional Neural Network*.
- Radha, P. (2025). Pneumonia Detection Using Chest X-Ray. *International Scientific Journal of Engineering and Management*, 04(02), 1–16. <https://doi.org/10.55041/isjem02263>
- Sadiq, Z., Rana, S., Mahfoud, Z., & Raoof, A. (2021). Systematic review and meta-analysis of chest radiograph (CXR) findings in COVID-19. *Clinical Imaging*, 80, 229–238. <https://doi.org/10.1016/j.clinimag.2021.06.039>
- Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. *Journal of Big Data*, 6(1). <https://doi.org/10.1186/s40537-019-0197-0>
- Singh, S., Kumar, M., Kumar, A., Verma, B. K., Abhishek, K., & Selvarajan, S. (2024). Efficient pneumonia detection using Vision Transformers on chest X-rays. *Scientific Reports*, 14(1), 1–17. <https://doi.org/10.1038/s41598-024-52703-2>
- Troeger, C., Blacker, B., Khalil, I. A., Rao, P. C., Cao, J., Zimsen, S. R. M., Albertson, S. B., Deshpande, A., Farag, T., Abebe, Z., Adetifa, I. M. O., Adhikari, T. B., Akibu, M., Al Lami, F. H., Al-Eyadhy, A., Alvis-Guzman, N., Amare, A. T., Amoako, Y. A., Antonio, C. A. T., ... Reiner, R. C. (2018). Estimates of the global, regional, and national morbidity, mortality, and aetiologies of lower respiratory infections in 195 countries, 1990–2016: a systematic analysis for the Global Burden of Disease Study 2016. *The Lancet Infectious Diseases*, 18(11), 1191–1210. [https://doi.org/10.1016/S1473-3099\(18\)30310-4](https://doi.org/10.1016/S1473-3099(18)30310-4)
- Virkki, R., Juven, T., Rikalainen, H., Svedström, E., Mertsola, J., & Ruuskanen, O. (2002). *Differentiation of bacterial and viral pneumonia in children*. 438–441. www.thoraxjnl.com
- World Health Organization. (2022, November 11). *Pneumonia in children*. <https://www.who.int/news-room/fact-sheets/detail/pneumonia>
- World Health Organization. (2024). *The top 10 causes of death*. <https://www.who.int/news-room/fact-sheets/detail/the-top-10-causes-of-death>